

Modelo Preditivo Para Prognóstico de Pacientes com COVID-19

Diego Kreutz

Orientador

Gustavo Cardozo

Orientando

Mirkos Martins

Co-orientador

Pandemia de COVID-19

- **181 milhões** de casos confirmados
- **3,9 milhões** de óbitos



Pandemia de COVID-19

- **181 milhões** de casos confirmados
- **3,9 milhões** de óbitos
 - 510 mil brasileiros

TOP 2 no ranking de
países com maior
número de óbitos
COVID-19



Cenário caótico de pandemia

Problemas quanto a disponibilidade de recursos hospitalares



<https://www.saude.ce.gov.br/2020/05/21/centrais-de-ventiladores-mecanicos-valida-respiradores-adquiridos-pelo-governo-do-estado/>



http://www.aen.pr.gov.br/modules/noticias/article.php?story_id=107854&tit=Governo-do-Estado-ja-abriu-913-leitos-de-UTI-para-Covid-19

Cenário caótico de pandemia

PANDEMIA

Quem poderá ter prioridade em leitos de UTI em meio à crise hospitalar em Caxias

Diretores dos hospitais da cidade anunciaram que sistema está em colapso e já admitem que terão que escolher quem atender

17/12/2020 - 15h27min
Atualizada em 18/12/2020 - 09h49min



MAIS LID

CONTEÚDO PUBLICITÁRIO

<https://gauchazh.clicrbs.com.br/pioneiro/geral/noticia/2020/12/quem-podera-ter-prioridade-em-leitos-de-uti-em-meio-a-crise-hospitalar-em-caxias-ckit5m3lg000k019ww6q3ikj8.html>

Cenário caótico de pandemia

PANDEMIA

Quem poderá ter prioridade em leitos de UTI em meio à crise hospitalar em Caxias

“têm prioridade os pacientes com alta probabilidade de recuperação”

Anunciaram que sistema está em colapso e já admitem que terão que escolher quem atender

- 09h49min



MAIS LID

CONTEÚDO PUBLICITÁRIO

Cenário caótico de pandemia

Situação crítica

Protocolo da Sesa indica quais pacientes devem ser priorizados para UTIs

Documento redigido pela Secretaria de Estado da Saúde – que está em fase de validação – indica que, em caso de limitação de leitos, serão priorizados os pacientes com a Covid-19 que tenham mais chances de sobreviver

Murilo Cuzzuol | Repórter

mcuzzuol@redegazeta.com.br

Vitória / Rede Gazeta

Publicado em 29/03/2021 às 16h30



Cenário caótico de pandemia

“Não devem ser priorizados pacientes com doença grave avançada”

Situação crítica

Protocolo da Sesau indica quais pacientes devem ser priorizados para UTIs

nto elaborado pela Secretaria de Estado da Saúde – que está em fase de validação – indica que, em caso de limitação de leitos, serão priorizados os pacientes com a Covid-19 que tenham mais chances de sobreviver

Murilo Cuzzuol | Repórter

mcuzzuol@redegazeta.com.br

Vitória / Rede Gazeta

Publicado em 29/03/2021 às 16h30



Cenário caótico de pandemia

Situação crítica

Protocolo da Sesa indica quais pacientes devem ser priorizados para UTI

“deve ser priorizado paciente criticamente enfermo sem limitações para intervenção

Documento redigido pela Secretaria de Estado da Saúde – que está em fase de validação – indica que, em caso de limitação de leitos, serão priorizados os pacientes com a Covid-19 que tenham mais chances de sobreviver

Murilo Cuzzuol | Repórter

mcuzzuol@redegazeta.com.br

Vitória / Rede Gazeta

Publicado em 29/03/2021 às 16h30



COMO MELHORAR ESTE CENÁRIO?

Modelo de aprendizagem de máquina para classificar o risco de óbito



Roteiro

Estado da arte

Design do estudo e origem dos dados

Variáveis (características)

Métodos estatísticos

Implementação e resultados

Conclusão e considerações finais

Estado da arte - Classificação de risco e priorização de pacientes

	Métodos de aprendizagem de máquina usados	Características	Métricas de avaliação
(IWENDI et al. 2020)	Floresta Aleatória Intensificada (AdaBoost); Árvore de decisão; SVM; Naive Bayes Gaussiano	Demográficas; Clínicas	Acurácia; Precisão; Sensibilidade; F1 Score; Matriz de confusão
(POURHOMAYOUN; SHAKIBI, 2020)	Floresta Aleatória; Redes Neurais Artificiais; Árvore de decisão; KNN; Regressão Logística; SVM	Demográficas; Clínicas	ROC-AUC; Matriz de confusão
(ZHAO et al., 2020)	Regressão Logística	Clínicas	ROC-AUC
(YADAW et al., 2020)	Floresta aleatória; XGBoost; Regressão Logística; SVM	Demográficas; Clínicas	ROC-AUC
(CHENG et al. 2020)	Floresta aleatória	Clínicas; Laboratoriais	Acurácia; Sensibilidade; ROC-AUC; Matriz de confusão

Como escolher o melhor algoritmo?

	Métodos de aprendizagem de máquina usados	Características	Métricas de avaliação
(IWENDI et al. 2020)	Floresta Aleatória Intensificada (AdaBoost); Árvore de decisão; SVM; Naive Bayes Gaussiano	Demográficas; Clínicas	Acurácia; Precisão; Sensibilidade; F1 Score; Matriz de confusão
(POURHOMAYOUN; SHAKIBI, 2020)	Floresta Aleatória ; Redes Neurais Artificiais; Árvore de decisão; KNN; Regressão Logística; SVM		
(ZHAO et al., 2020)	Regressão Logística		
(YADAW et al., 2020)	Floresta aleatória ; XGBoost; Regressão Logística; SVM	Clinicas	
(CHENG et al. 2020)	Floresta aleatória	Clínicas; Laboratoriais	Acurácia; Sensibilidade; ROC-AUC; Matriz de confusão

Floresta Aleatória é o algoritmo mais utilizado

Como medir seu desempenho?

	Métodos de aprendizagem de máquina usados	Características	Métricas de avaliação
(IWENDI et al. 2020)	Floresta Aleatória Intensificada (AdaBoost); Árvore de decisão; SVM; Naive Bayes Gaussiano	Demográficas; Clínicas	Acurácia; Precisão; Sensibilidade; F1 Score; Matriz de confusão
(POURHOMAYOUN; SHAKIBI, 2020)	Floresta Aleatória; Artificial Neural Network; Regressão Logística	Demográficas; Clínicas	ROC-AUC; Matriz de confusão
(ZHAO et al., 2020)	Regressão Logística	Clínicas	ROC-AUC
(YADAW et al., 2020)	Floresta Aleatória; Regressão Logística; SVM	Demográficas; Clínicas	ROC-AUC
(CHENG et al. 2020)	Floresta aleatória	Clínicas; Laboratoriais	Acurácia; Sensibilidade; ROC-AUC; Matriz de confusão

Curva ROC e área AUC

Estado da arte

	Métodos de aprendizagem		Métricas de avaliação
(IWENDI et al. 2020)	Floresta Aleatória Integrada (AdaBoost); Árvore de decisão; Naive Bayes Gaussiano		Acurácia; Precisão; Sensibilidade; F1 Score; Matriz de confusão
(POURHOMAYOUN; SHAKIBI, 2020)	Floresta Aleatória; Redes Neurais Artificiais; Árvore de decisão; KNN; Regressão Logística; SVM	Demográficas; Clínicas	ROC-AUC; Matriz de confusão
(ZHAO et al., 2020)	Regressão Logística	Clínicas	ROC-AUC
(YADAW et al., 2020)	Floresta aleatória; XGBoost; Regressão Logística; SVM	Demográficas; Clínicas	ROC-AUC
(CHENG et al. 2020)	Floresta aleatória	Clínicas; Laboratoriais	Acurácia; Sensibilidade; ROC-AUC; Matriz de confusão

Esse método e métricas foram aplicados neste trabalho

Que características usar?

	Métodos de aprendizagem de máquina usados	Características	Métricas de avaliação
(IWENDI et al. 2020)	Floresta Aleatória Intensificada (AdaBoost); Árvore de decisão; SVM; Naive Bayes Gaussiano	Demográficas; Clínicas	Acurácia; Precisão; Sensibilidade; F1 Score; Matriz de confusão
(POURHOMAYOU N; SHAHROKH 2020)	Floresta Aleatória; Redes Neurais	Demográficas; Clínicas	ROC-AUC; Matriz de confusão
(ZHAO et al. 2020)		Clínicas	ROC-AUC
(YADA et al. 2020)		Demográficas; Clínicas	ROC-AUC
(CHENG et al. 2020)	Floresta aleatória	Clínicas; Laboratoriais	Acurácia; Sensibilidade; ROC-AUC; Matriz de confusão

Demográficas (idade e sexo)

Clínicas (tosse, febre e falta de ar)

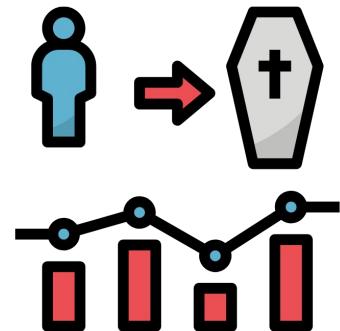


Relatório Transparente de um Modelo de Predição Multivariável para Diagnóstico ou Prognóstico Individual

Metodologia

SEÇÃO/TÓPICO	Item	Checklist Item	Página
Ítulo e Resumo			
Titúlo	1	Identificar se o estudo é o desenvolvimento e/ou validação de um modelo de predição multivariado, a população alvo, e o desfecho para ser predito	1
Resumo	2	Prover uma summarização dos objetivos, design do estudo, configurações, participantes, tamanho da amostra, variáveis preditoras, variável resposta, análise estatística, resultados e conclusões	13
Introdução			
Contextualização e Objetivos	3a	Explicar o contexto médico (Incluindo se é diagnóstico ou prognóstico), e relacionar com o desenvolvimento ou validação do modelo preditivo multivariado, incluindo referência para modelos existentes	15
	3b	Especificando os objetivos, incluindo o que o estudo descreve, se é o desenvolvimento de um modelo preditivo, a validação de um modelo ou ambos.	16
Métodos/metodologia			
Origem dos dados	4a	Descrever o design do estudo ou a origem dos dados (e.g., teste randomizado, coorte, ou registro dos dados), separadamente dos conjuntos de desenvolvimento e validação, se aplicável.	21
	4b	Especifique as principais datas do estudo, incluindo o início da acumulação; fim da acumulação; e, se aplicável, fim do acompanhamento	21
Participantes	5a	Especifique os elementos-chave do cenário do estudo (por exemplo, atenção primária, atenção secundária, população em geral), incluindo o número e a localização dos centros	21
	5b	Descrever o critério de inclusão (elegibilidade) dos pacientes	21/22
	5c	Dar detalhes do tratamento recebido, se for relevante.	Não se aplica
Outcome	6a	Definir claramente o desfecho (<i>outcome</i>) que será predito pelo modelo, incluindo como e quando avaliado	22
	6b	Relate quaisquer ações para avaliação cega do resultado a ser predito.	Não se aplica
Predtores	7a	Definir claramente todas as variáveis preditoras usadas no desenvolvimento ou validação do modelo preditivo multivariado, incluindo como e quando elas foram medidas	22/23
	7b	Reportar quaisquer ações para avaliação cega das preditoras para o <i>outcome</i> e outras preditoras	Não se aplica
Tamanho da amostra	8	Explique como chegou ao tamanho do estudo.	21/22
Dados faltantes	9	Descrever como os dados faltantes foram tratados (e.g., análise de caso completo, imputação simples, imputação múltipla) com detalhes de quaisquer método de imputação.	21
Métodos estatísticos	10a	Descrever como as variáveis preditoras foram tratadas na análise	22
	10b	Especificando o tipo do modelo, todos os processos para a construção do modelo (incluindo qualquer seleção de variável preditora), e métodos para validação interna	24
	10c	Especificando todas as métricas usadas para avaliar a performance do modelo, e se for relevante, para comparar com múltiplos modelos	24/25
Grupos de risco	11	Prover detalhes de como grupos de risco foram criados, se feito.	Não se aplica
Resultados			
Participantes	13a	Descreva o fluxo de participantes durante o estudo, incluindo o número de participantes com e sem o desfecho e, se aplicável, um resumo do tempo de acompanhamento. Um diagrama pode ser útil.	27/28
	13b	Descreva as características dos participantes (dados demográficos básicos, características clínicas, predtores disponíveis), incluindo o número de participantes com dados ausentes para preditor e variável resposta	27/28
Desenvolvimento do modelo	14a	Especificando o número de participantes com e sem desfecho (<i>outcome events</i>) em cada análise	30/31
	14b	Se feito, relatar a associação não ajustada entre cada preditor candidato e desfecho.	Não se aplica
Especificação do modelo	15a	Apresentar o modelo de predição completo para permitir previsões para indivíduos (ou seja, todos os coeficientes de regressão e interceptação do modelo ou sobrevida de linha de base em um determinado ponto de tempo).	Não se aplica
	15b	Explicar como usar o modelo preditivo	30
Performance do modelo	16	Detalhar a concordância do desempenho (item 10c) para o modelo de predição	24

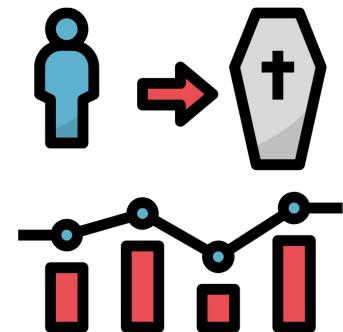
Risco de enviesamento



Objetivo mal definido

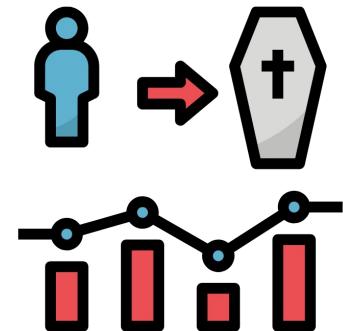
Risco de enviesamento

Objetivo mal definido



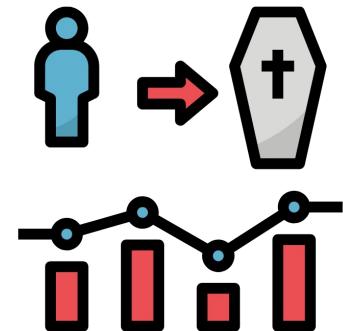
Risco de enviesamento

Poucos dados ou
estudo mal
reportado



Objetivo

Risco de enviesamento

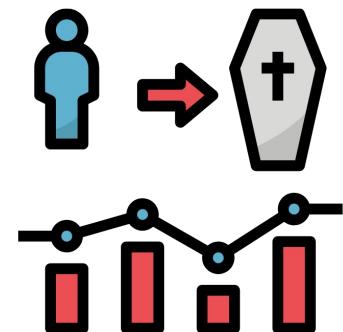


Objetivo mal definido

Risco de envio

Pobreza no detalhamento

Objetivo mal definido



Roteiro

Estado da arte

Design do estudo e origem dos dados

Variáveis (características)

Métodos estatísticos

Implementação e resultados

Conclusão e considerações finais

Dados: Estado do Rio Grande do Sul



**CORONAVÍRUS
COVID-19**

<https://ti.saude.rs.gov.br/covid19/>

Dados: Estado do Rio Grande do Sul



**01 de janeiro
2021**

**08 de junho
2021**

Dados: Estado do Rio Grande do Sul



**01 de janeiro
2021**

**08 de junho
2021**

604.389 registros

Dados: Estado do Rio Grande do Sul



Todos os casos
que foram
reportados no
intervalo de tempo



**08 de junho
2021**

604.389 registros

Dados: Estado do Rio Grande do Sul



**01 de janeiro
2021**



Todos analisados
como casos
únicos, casos de
reinfecção foram
ignorados

604.389 registros

Roteiro

Estado da arte

Design do estudo e origem dos dados

Variáveis (características)

Métodos estatísticos

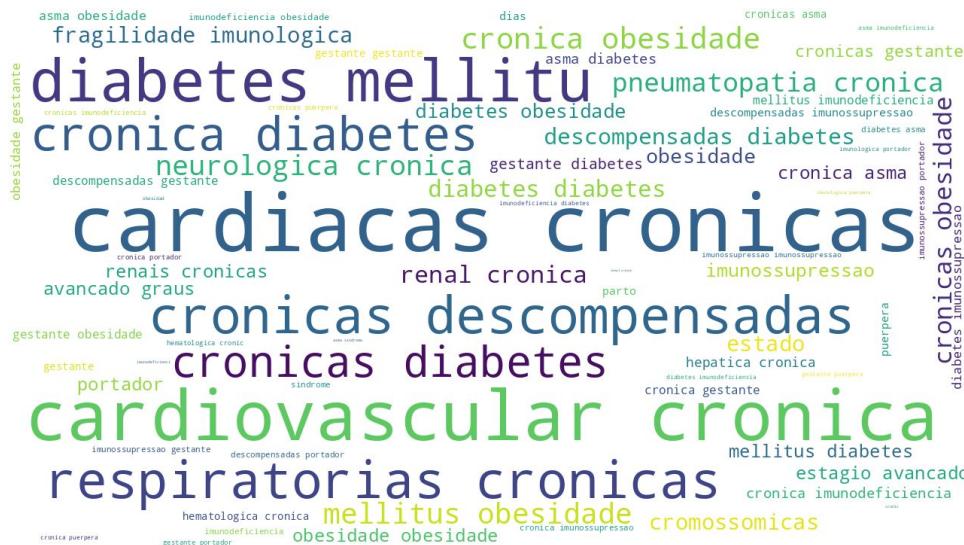
Implementação e resultados

Conclusão e considerações finais

Engenharia de características

Extração de características

CONDICOES



Extração de características

‘CONDICOES’:



Cardiopatia

Diabetes

Doença respiratória

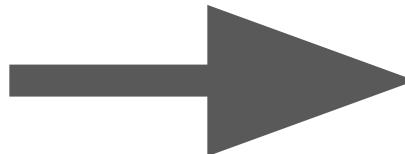
→ Problema renal

Obesidade

Doença cromossômica

Codificação de rótulos

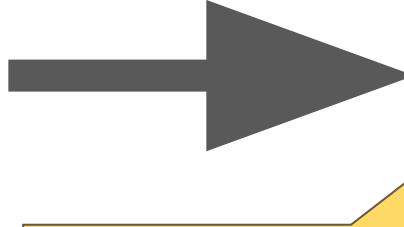
Valor
Sim
Não
Não
Sim
Não
Sim



código
1
0
0
1
0
1

Codificação de rótulos

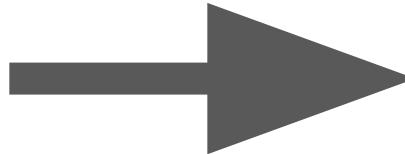
Valor	código
Sim	1
Não	0
Não	0
Sim	1
Não	0
Sim	1



Transformar em algo “legível” para máquina

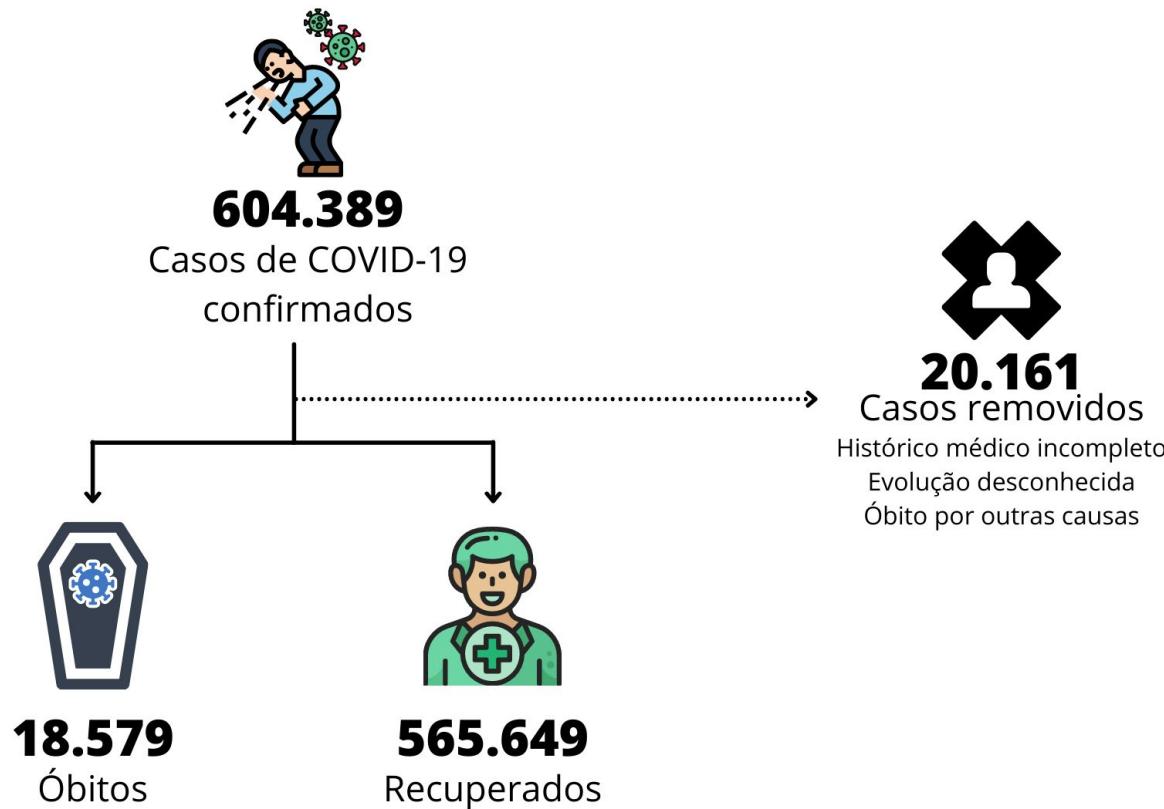
Codificação de rótulos - Faixa etária

Valor
“< 1”
“01 a 04”
“05 a 09”
“10 a 14”
“15 a 19”
“20 a 29”
“30 a 39”
...
“60 a 69”
“70 a 79”
“80 e mais”

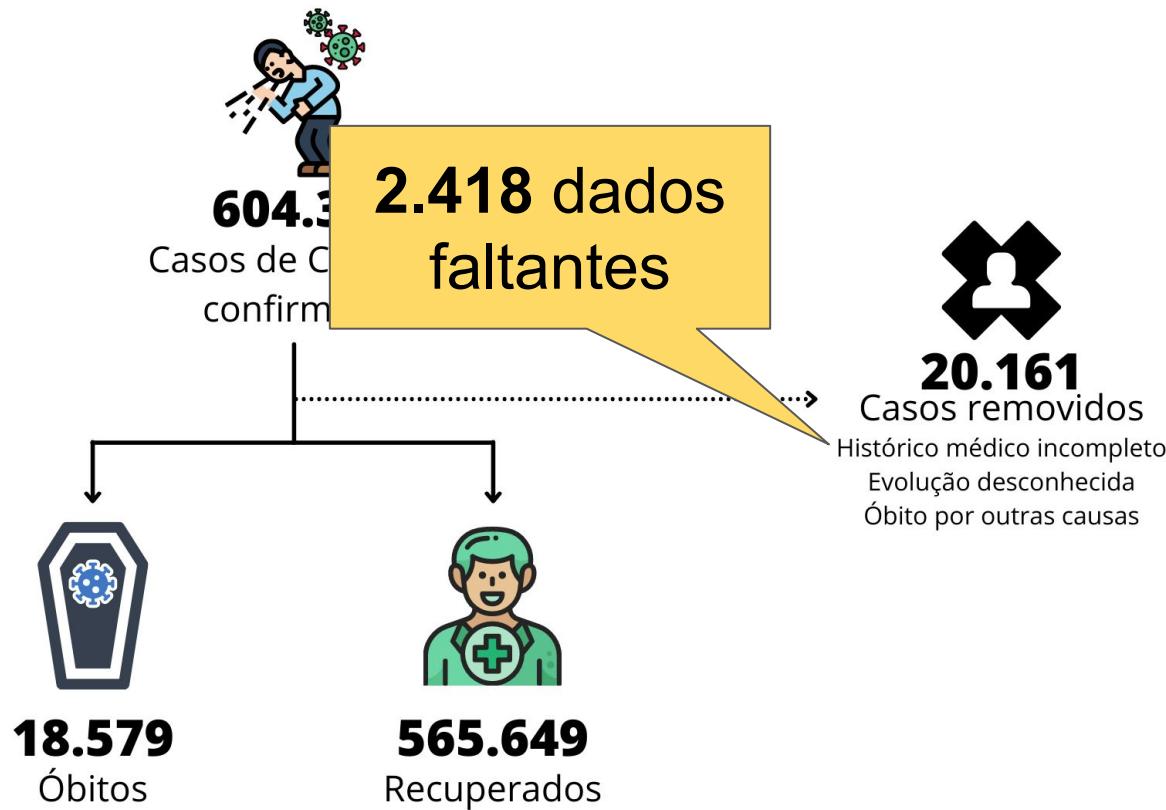


Código
0
1
2
3
4
5
6
...
9
10
11

Seleção de dados



Seleção de dados



Seleção de dados



604.389

17.724 casos em
acompanhamento



18.579

Óbitos



565.649

Recuperados



20.161

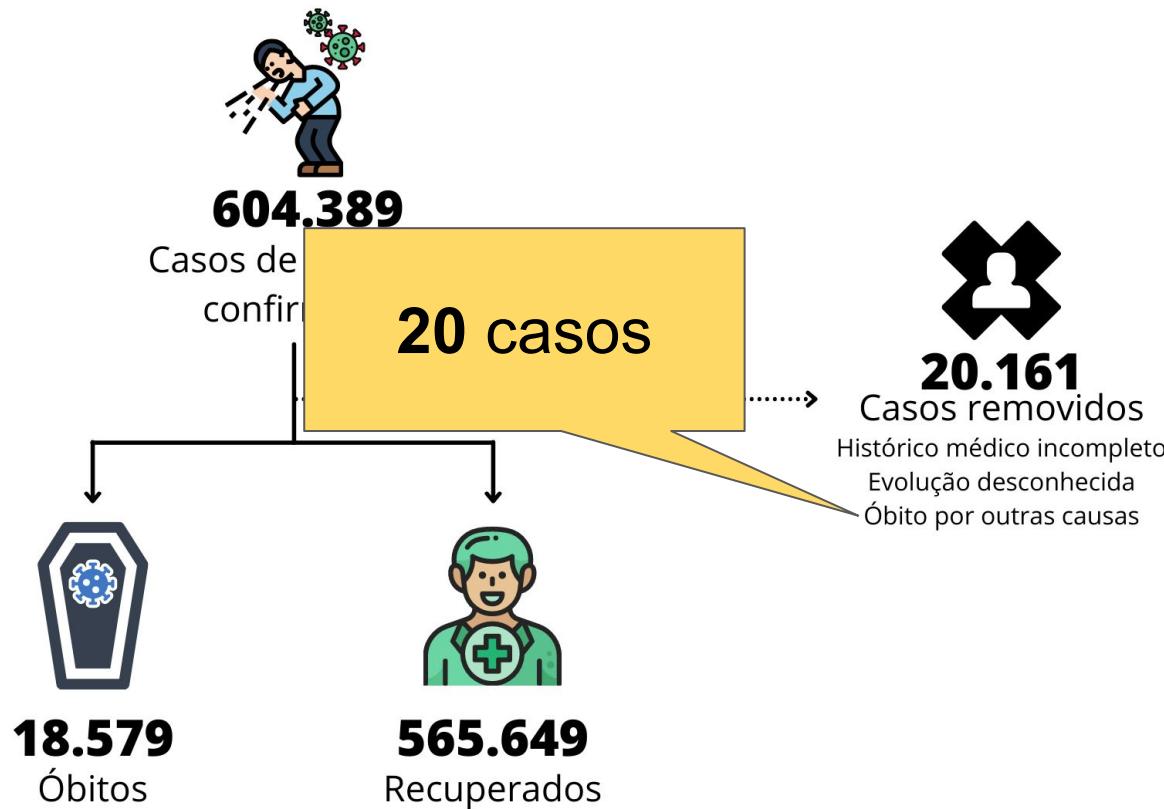
Casos removidos

Histórico médico incompleto

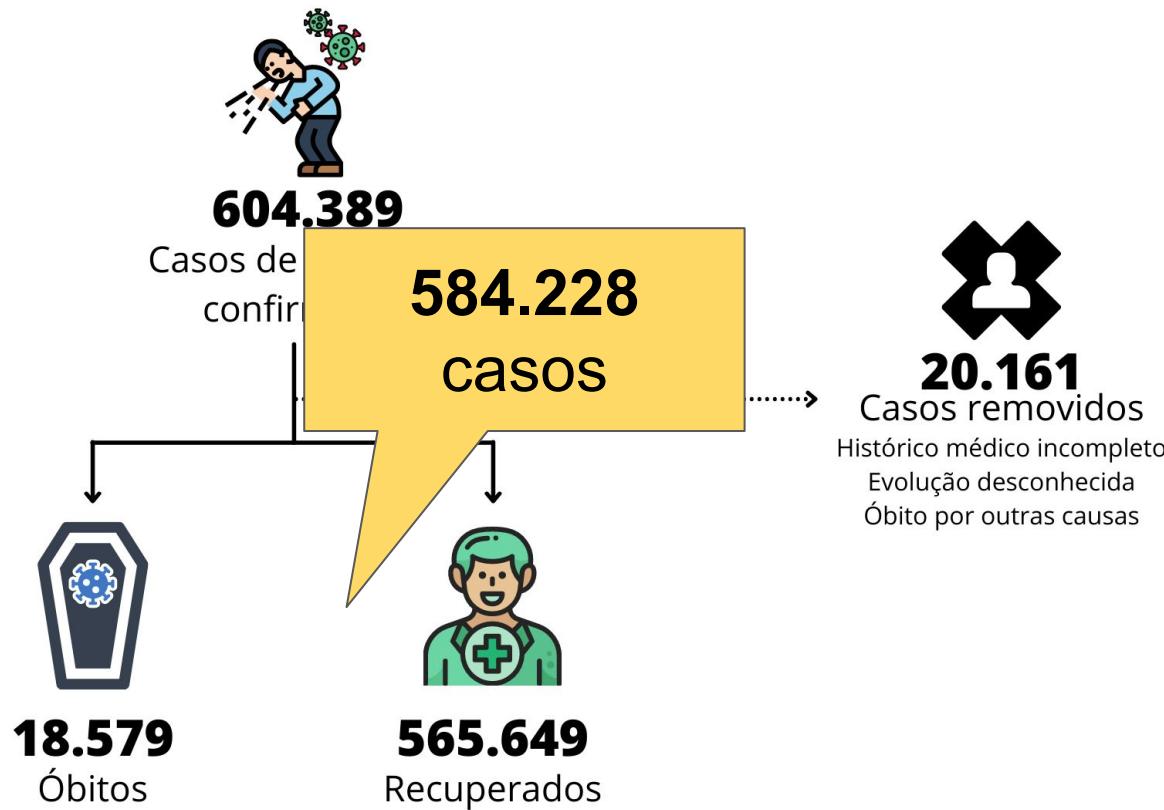
Evolução desconhecida

Óbito por outras causas

Seleção de dados



Seleção de dados



Tamanho da amostra

Linhas	604.389
Colunas	30

Tamanho da amostra

Linhas	604.389
Colunas	30

**Remoção dos
dados
faltantes**

Tamanho da amostra

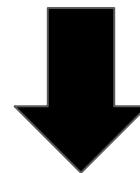
Linhas	604.389
Colunas	30

**Remoção dos
dados
faltantes**

**Remoção das
variáveis que não
são candidatas a
preditoras (datas e
códigos)**

Tamanho da amostra

Linhas	604.389
Colunas	30

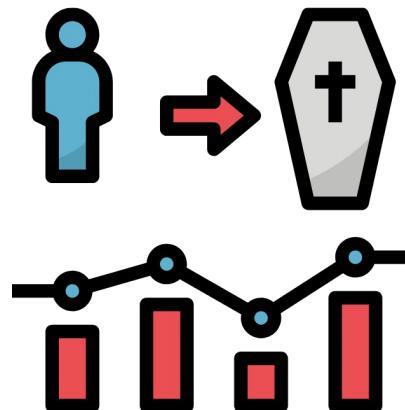


Linhas	584.228
Colunas	15

Variável resposta

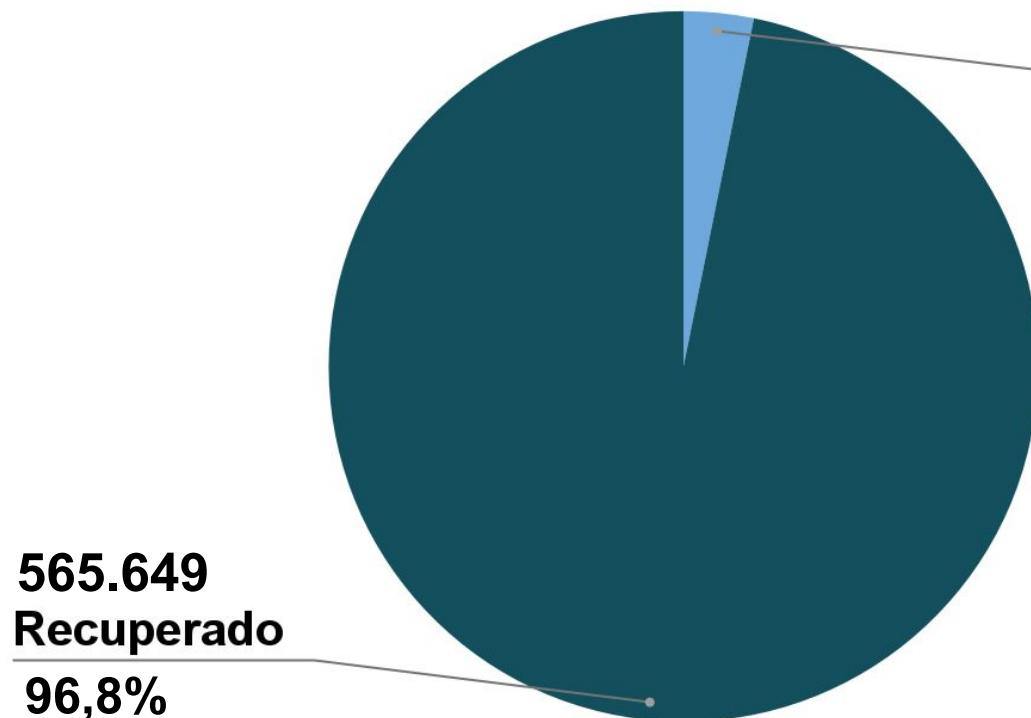
Variável de desfecho

Propor um **modelo preditivo** para **classificação de risco de mortalidade** de pacientes com COVID-19.



EVOLUÇÃO

Distribuição das evoluções



18.579
Óbito
3,2%

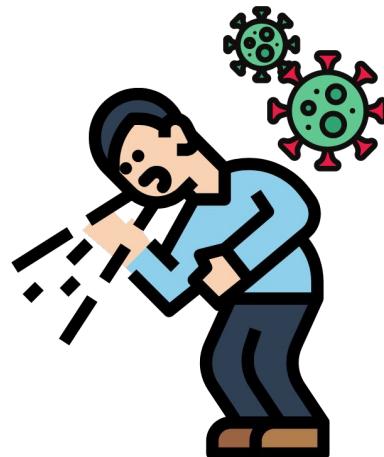
565.649
Recuperado
96,8%

Preditores

Variáveis preditoras

Variáveis demográficas: **Sexo e faixa-etária**

Variáveis clínicas: **sintomas gripais e comorbidades**



Variáveis preditoras

Variável

SEXO

FAIXAETARIA

FEBRE

TOSSE

GARGANTA

DISPNEIA

SRAG

Variável

GESTANTE

CADIOPATIA

DIABETES

DOENCA_RESPIRATORIA

PROBLEMA_RENAL

OBESIDADE

DOENCA_CROMOSSOMICA

Roteiro

Estado da arte

Design do estudo e origem dos dados

Variáveis (características)

Métodos estatísticos

Implementação e resultados

Conclusão e considerações finais

Perfil dos participantes

Perfil dos participantes

Correlações entre as características (Pearson)

Perfil dos participantes

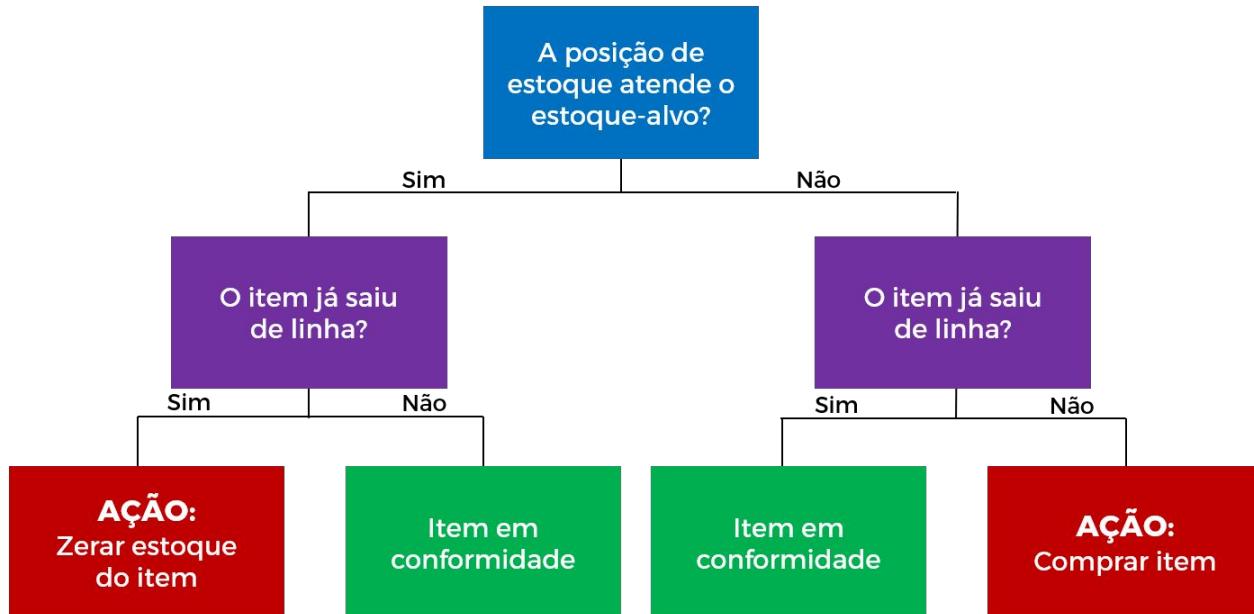
Correlações entre as características (Pearson)

Importância de características (Grau de impureza Gini)

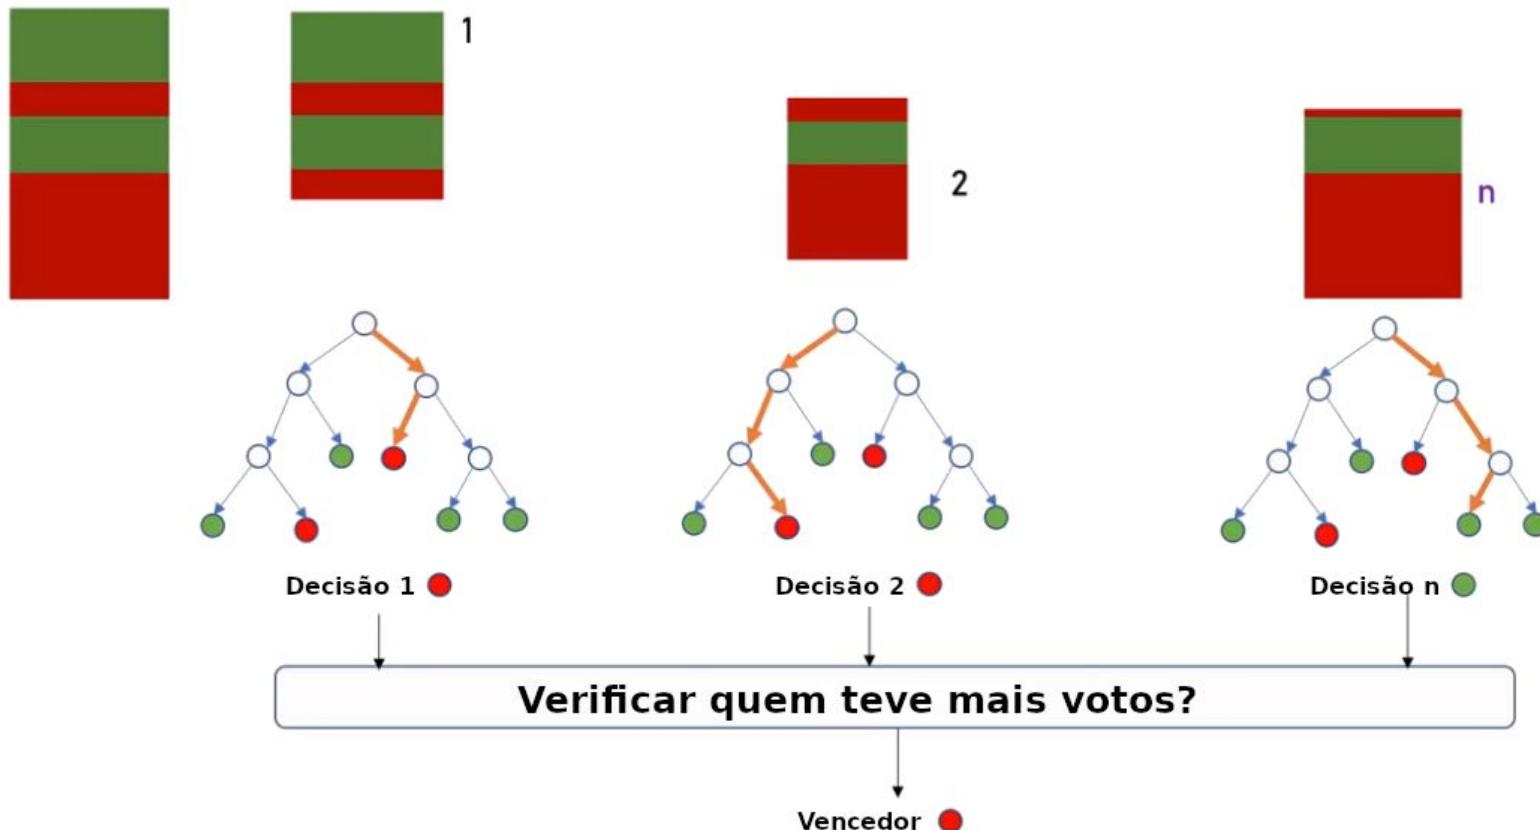
Análise descritiva

Análise preditiva

Análise preditiva - Árvore de decisão



Análise preditiva - Floresta aleatória



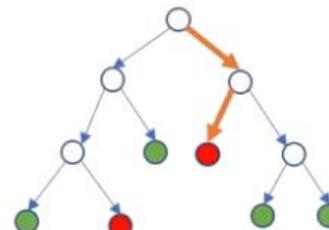
Análise preditiva - Floresta aleatória



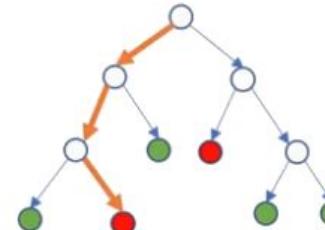
1



2



Decisão 1 ●



Decisão 2 ●

tendem a ser mais robustas que árvores de decisão



Decisão n ●

Verificar quem teve mais votos?

Vencedor ●

Análise preditiva - Dados de treino

584.228

Todos os dados

565.649 Recuperados

18.579 Óbitos

Análise preditiva - Dados de treino

584.228

Todos os dados

565.649 Recuperados

18.579 Óbitos

**Treinar com
todos os dados
disponíveis**

Análise preditiva - Sobreajuste

584.228

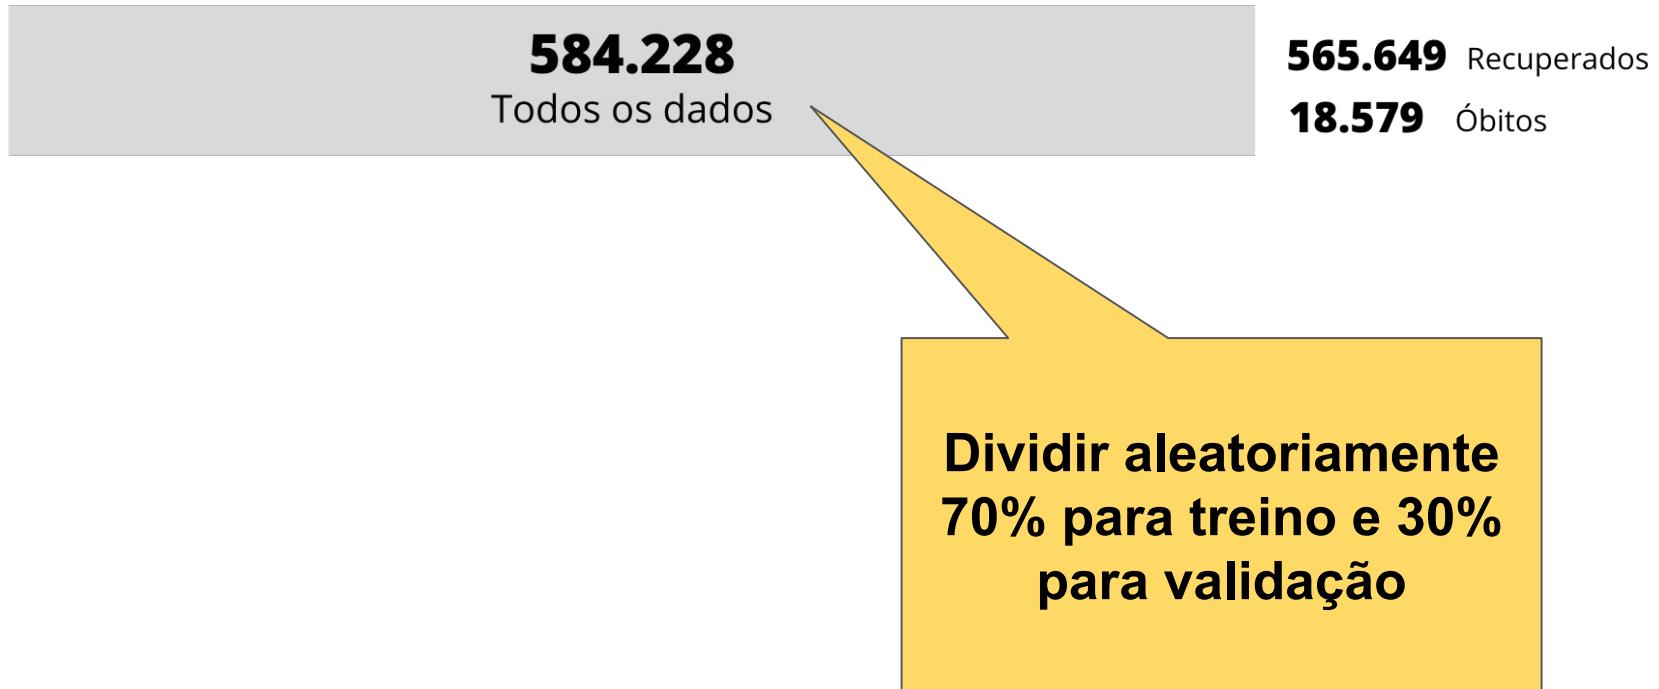
Todos os dados

565.649 Recuperados

18.579 Óbitos

Modelo pode “decorar” os dados
Não funcionar para dados futuros

Análise preditiva - Dados



Análise preditiva - Dados

30% aleatório. Mas e quantos óbitos e recuperados foram escolhidos?

565.649 Recuperados
18.579 Óbitos

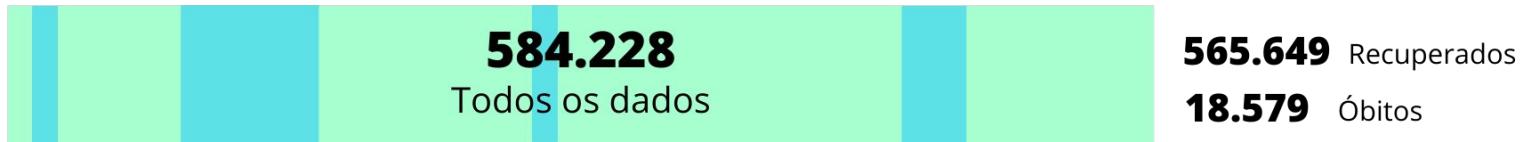
408.959

Dados de treino e teste

175.269

Dados de validação

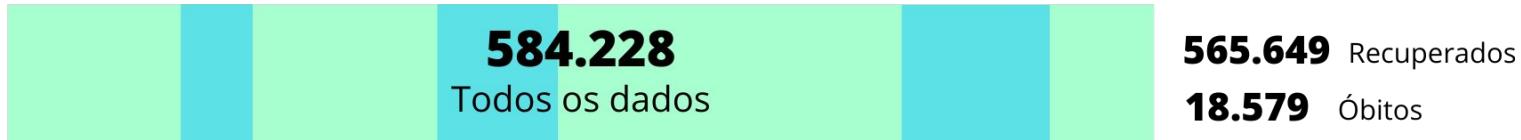
Análise preditiva - Dados



396.050 Recuperados
12.909 Óbitos

169.599 Recuperados
5.670 Óbitos

Análise preditiva - Dados



395.880 Recuperados

13.079 Óbitos

169.769 Recuperados

5.500 Óbitos

Análise preditiva - Dados



395.977 Recuperados
12.982 Óbitos

169.672 Recuperados
5.597 Óbitos

Análise preditiva - Dados

584.228

Todos os dados

408.959

Dados de treino e teste

Escolhemos uma
divisão
estratificada

Recuperados
Óbitos

175.269

Dados de validação

Análise preditiva - Dados

584.228

Todos os dados

408.959

Dados de treino e teste

395.954 Recuperados

13.005 Óbitos

565.649 Recuperados

10.770 Óbitos

**Sempre a mesma
proporção**

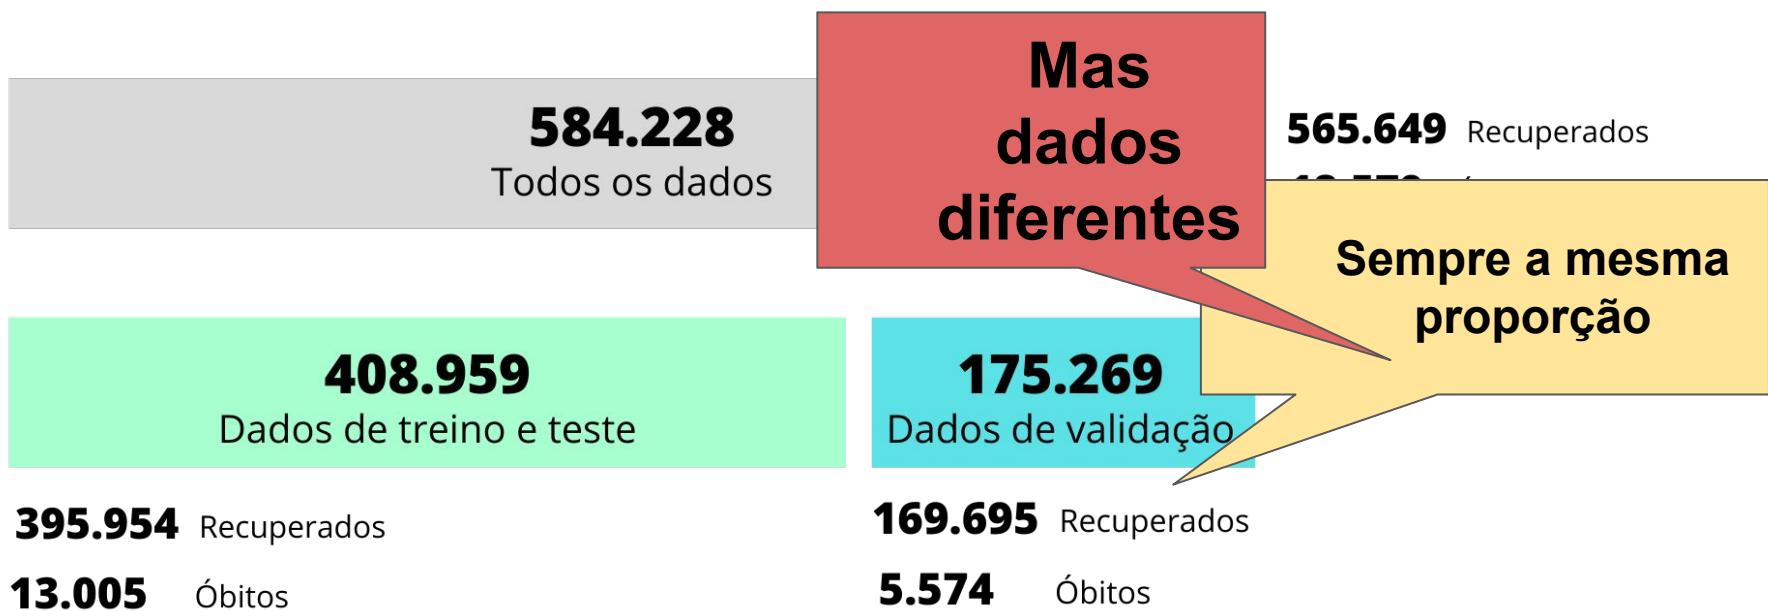
175.269

Dados de validação

169.695 Recuperados

5.574 Óbitos

Análise preditiva - Dados



Validação cruzada

Análise preditiva - Validação cruzada k - fold

395.954 Recuperados

13.005 Óbitos

408.959

Dados de treino e teste

175.269

Dados de validação

169.695 Recuperados

5.574 Óbitos

Análise preditiva - Validação cruzada k - fold



Análise preditiva - Validação cruzada k - fold

395.954 Recuperados

13.005 Óbitos

408.959

Dados de treino e teste

175.269

Dados de validação

169.695 Recuperados

5.574 Óbitos

Divisão 1

Fold 1

Fold 2

Fold 3

Fold 4

Fold 5

Treino

Análise preditiva - Validação cruzada k - fold

395.954 Recuperados

13.005 Óbitos

408.959

Dados de treino e teste

175.269

Dados de validação

169.695 Recuperados

5.574 Óbitos

Divisão 1

Fold 1

Fold 2

Fold 3

Fold 4

Fold 5

Teste

Análise preditiva - Validação cruzada k - fold

395.954 Recuperados

13.005 Óbitos

408.959

Dados de treino e teste

175.269

Dados de validação

169.695 Recuperados

5.574 Óbitos

Divisão 1

Fold 1

Fold 2

Fold 3

Fold 4

Fold 5

Divisão 2

Fold 1

Fold 2

Fold 3

Fold 4

Fold 5

Análise preditiva - Validação cruzada k - fold

395.954 Recuperados

13.005 Óbitos

408.959

Dados de treino e teste

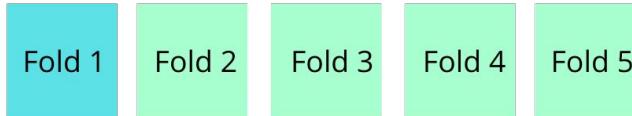
175.269

Dados de validação

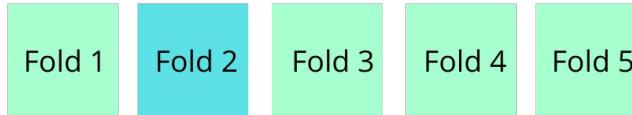
169.695 Recuperados

5.574 Óbitos

Divisão 1

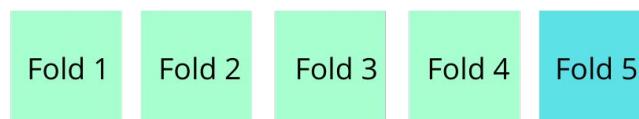


Divisão 2



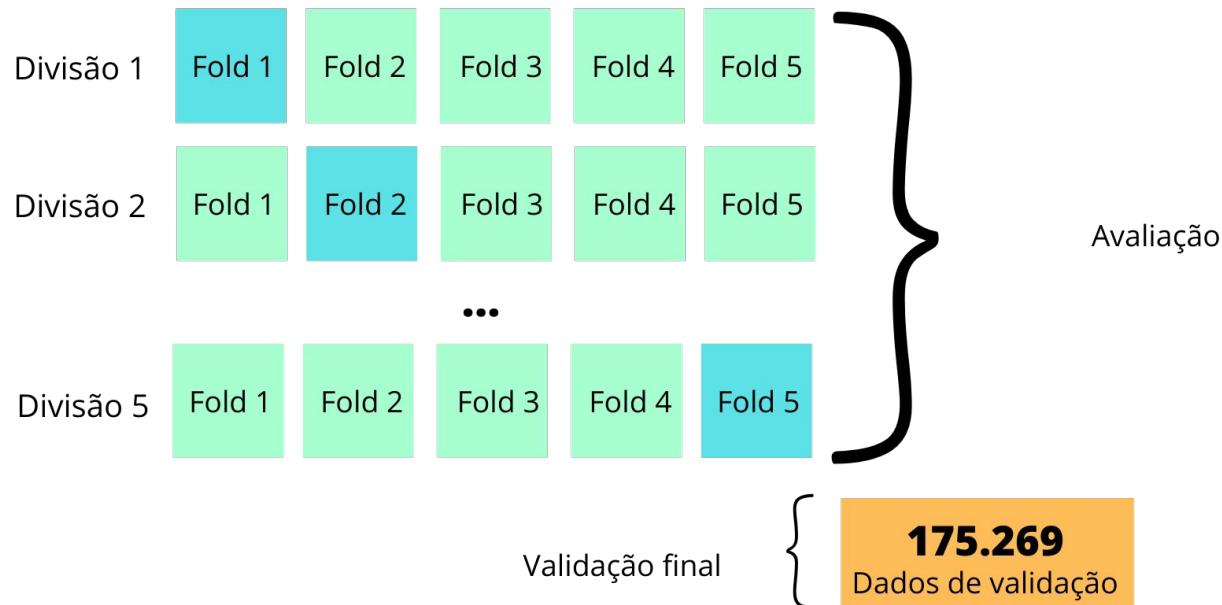
...

Divisão 5



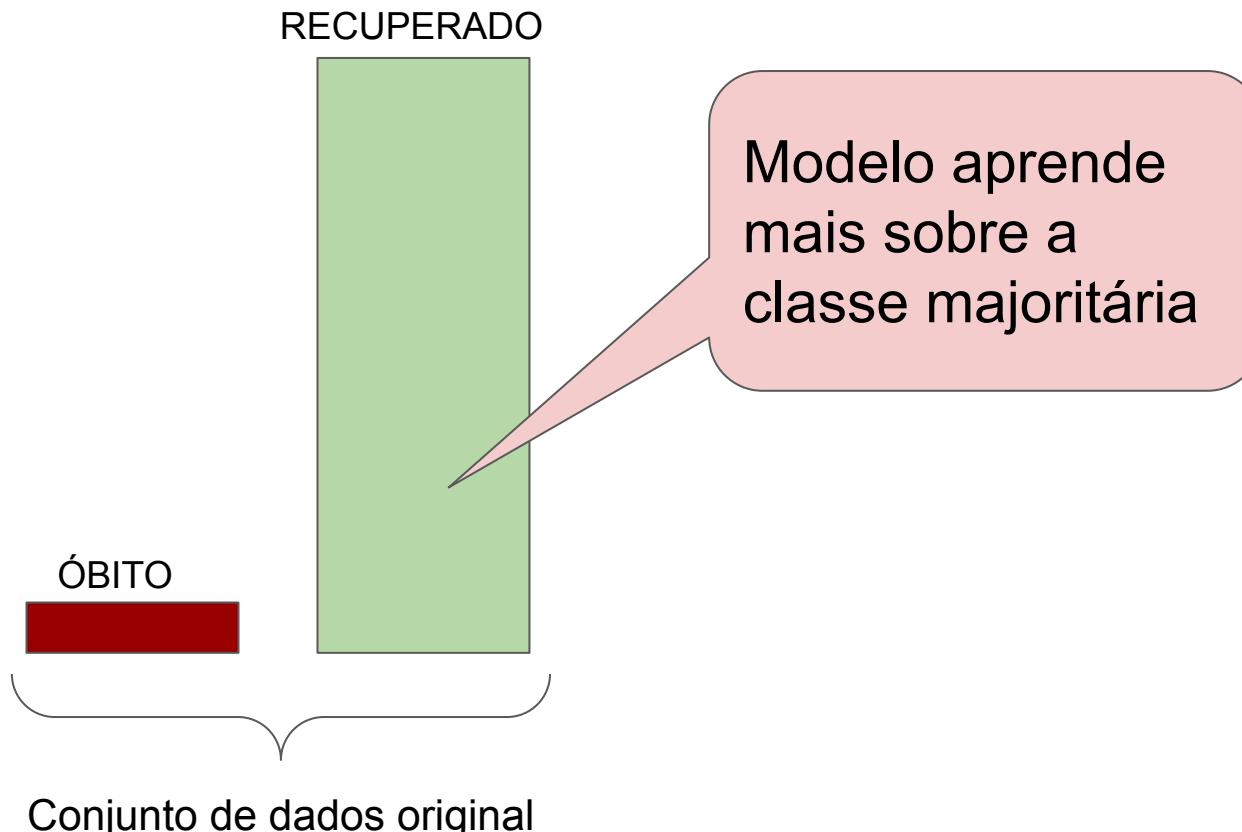
Análise preditiva - Validação cruzada k - fold

395.954 Recuperados	408.959 Dados de treino e teste	175.269 Dados de validação	169.695 Recuperados
13.005 Óbitos			5.574 Óbitos

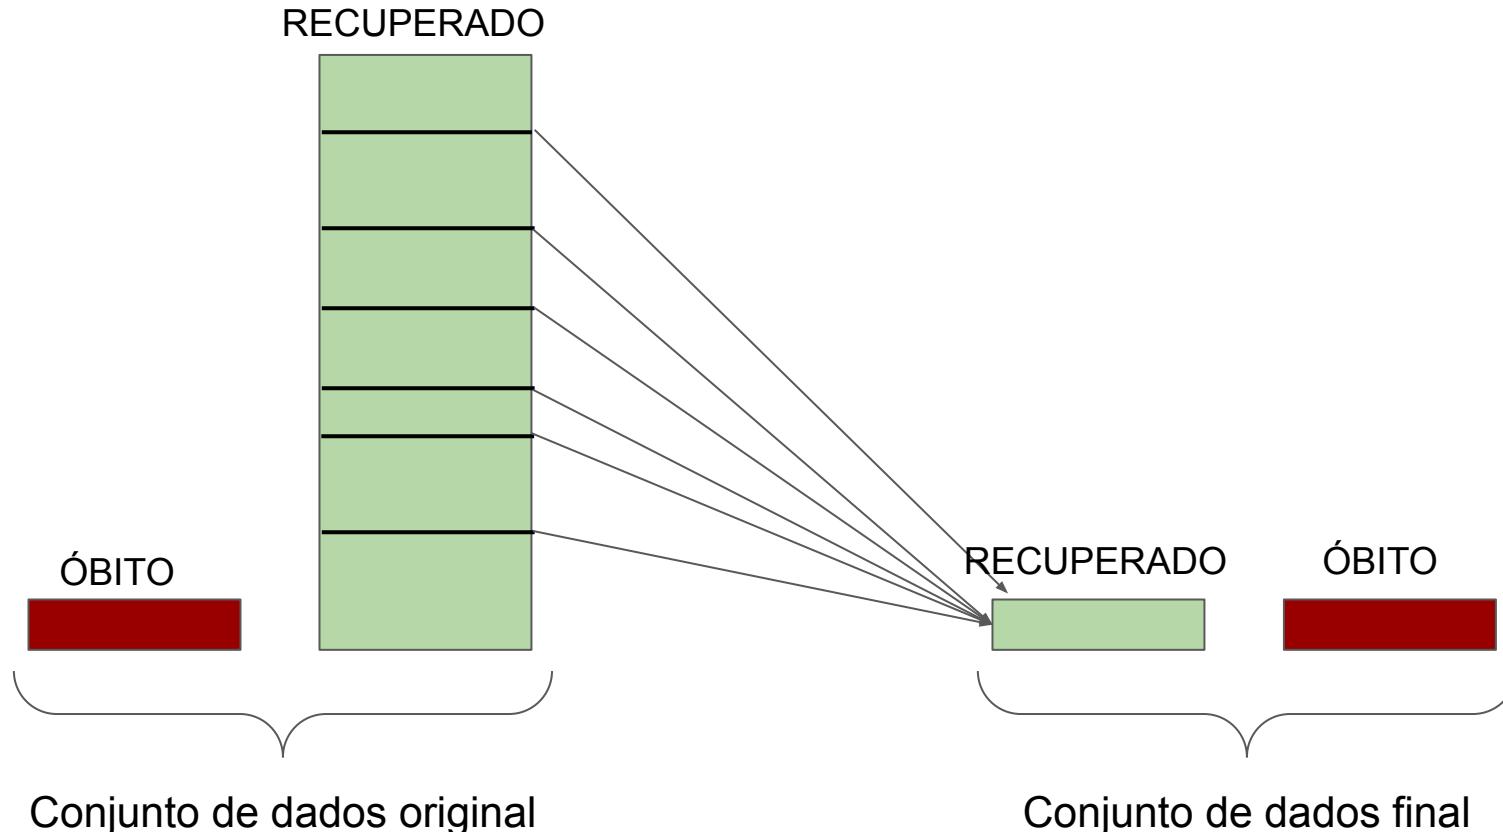


Dados desbalanceados

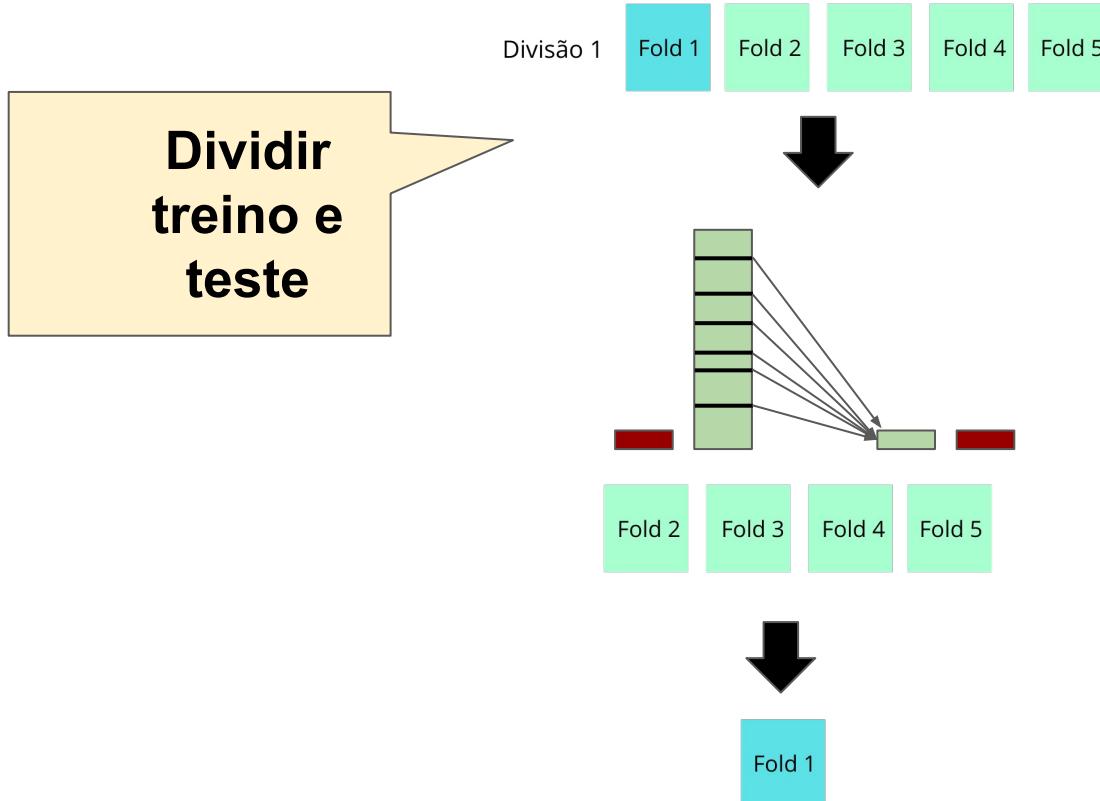
Análise preditiva - Dados desbalanceados



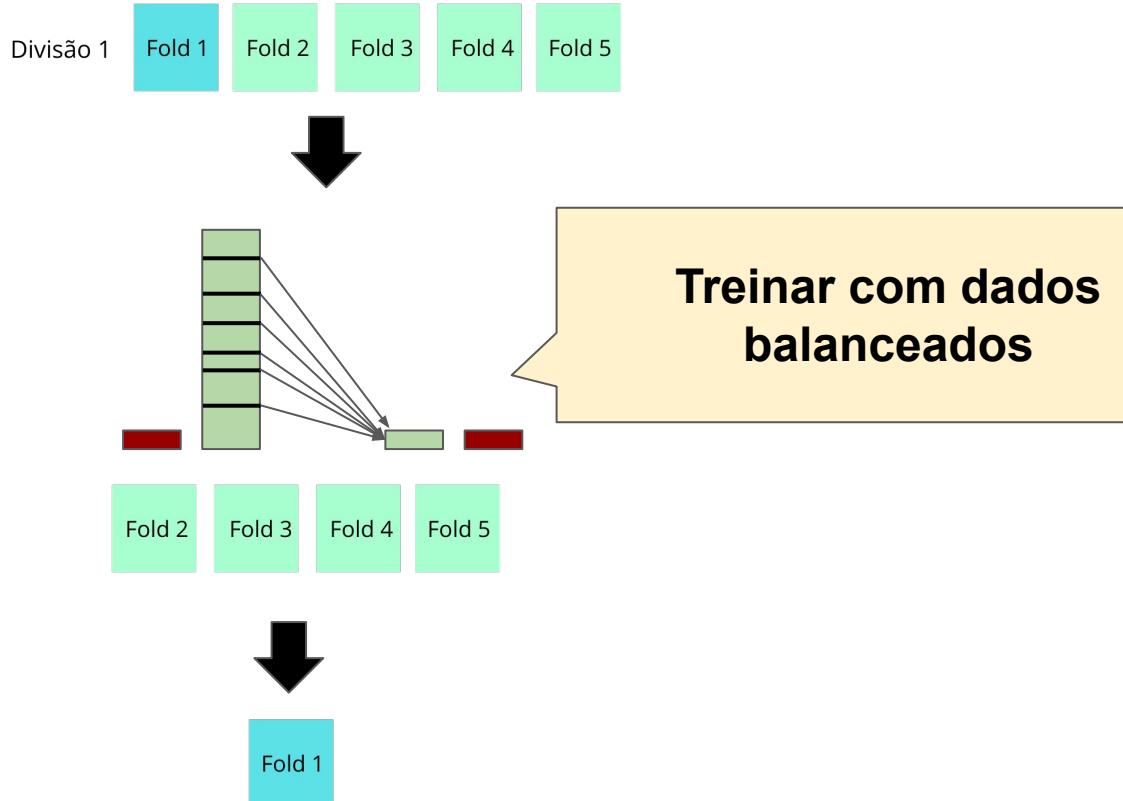
Análise preditiva - Subamostragem aleatória



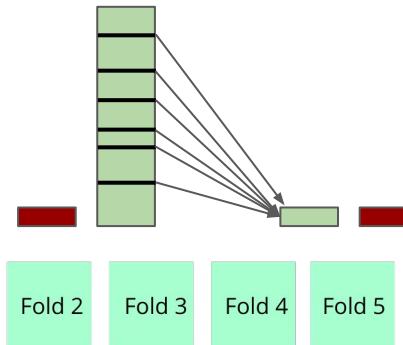
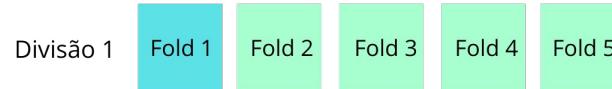
Análise preditiva - Validação cruzada + subamostragem



Análise preditiva - Validação cruzada + subamostragem



Análise preditiva - Validação cruzada + subamostragem

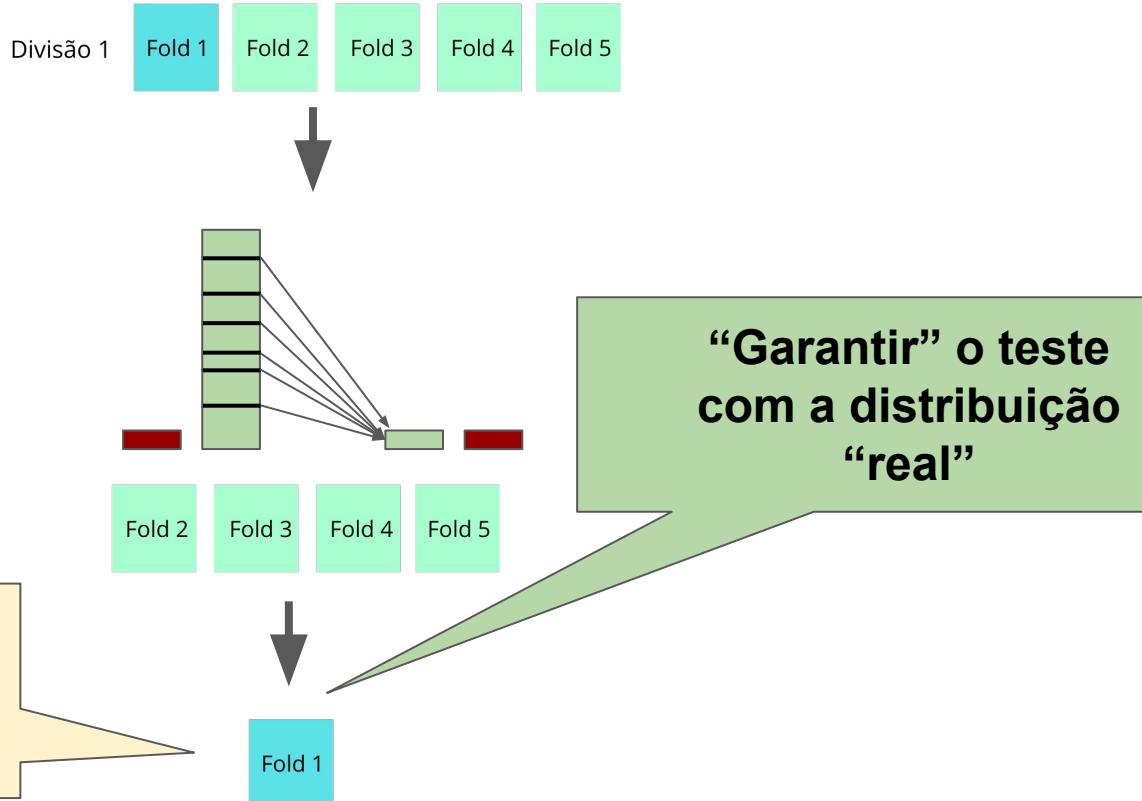


Testar com dados desbalanceados



Fold 1

Análise preditiva - Validação cruzada + subamostragem



Métrica de avaliação

Análise preditiva - métrica de avaliação

Desfecho Real
Recuperado
Óbito

Análise preditiva - métrica de avaliação

Desfecho Real	Prognóstico Preditivo
Recuperado	Recuperado
Óbito	Recuperado

Análise preditiva - métrica de avaliação

Desfecho Real	Prognóstico Preditivo
Recuperado	Recuperado
Óbito	Recuperado

Modelo acertou 9
de 10 = 90% de
acurácia

Análise preditiva - métrica de avaliação

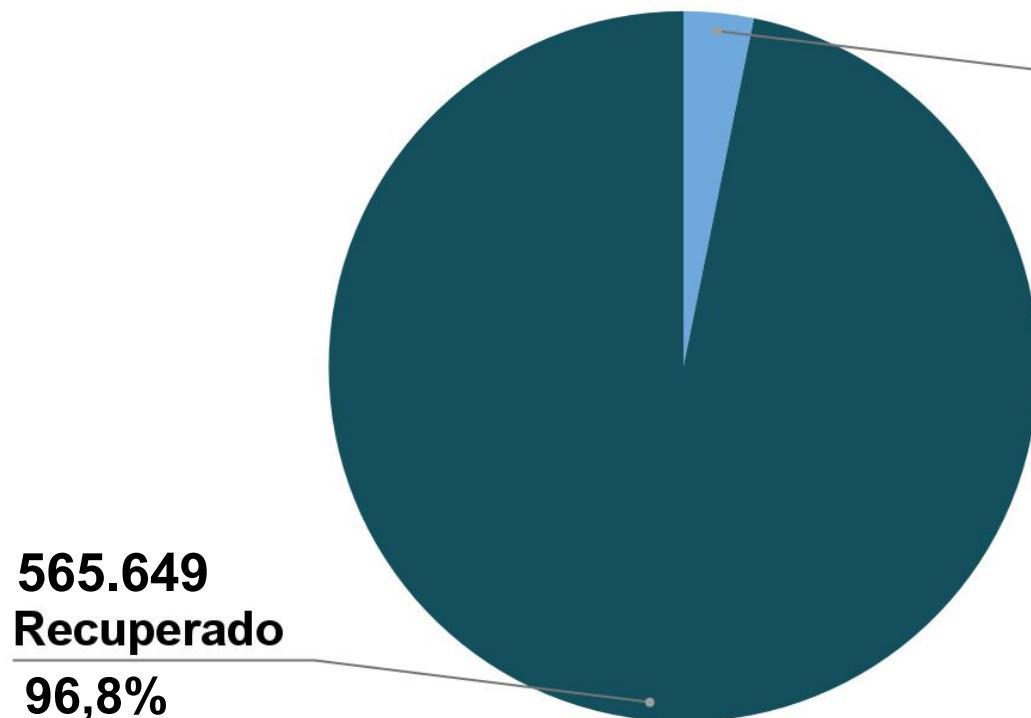
Desfecho Real	Prognóstico Preditivo
Recuperado	Recuperado
Óbito	Recuperado

Modelo acertou 9
de 10 = 90% de
acurácia

Total de acertos /
Total de casos

EVOLUÇÃO

Distribuição das evoluções

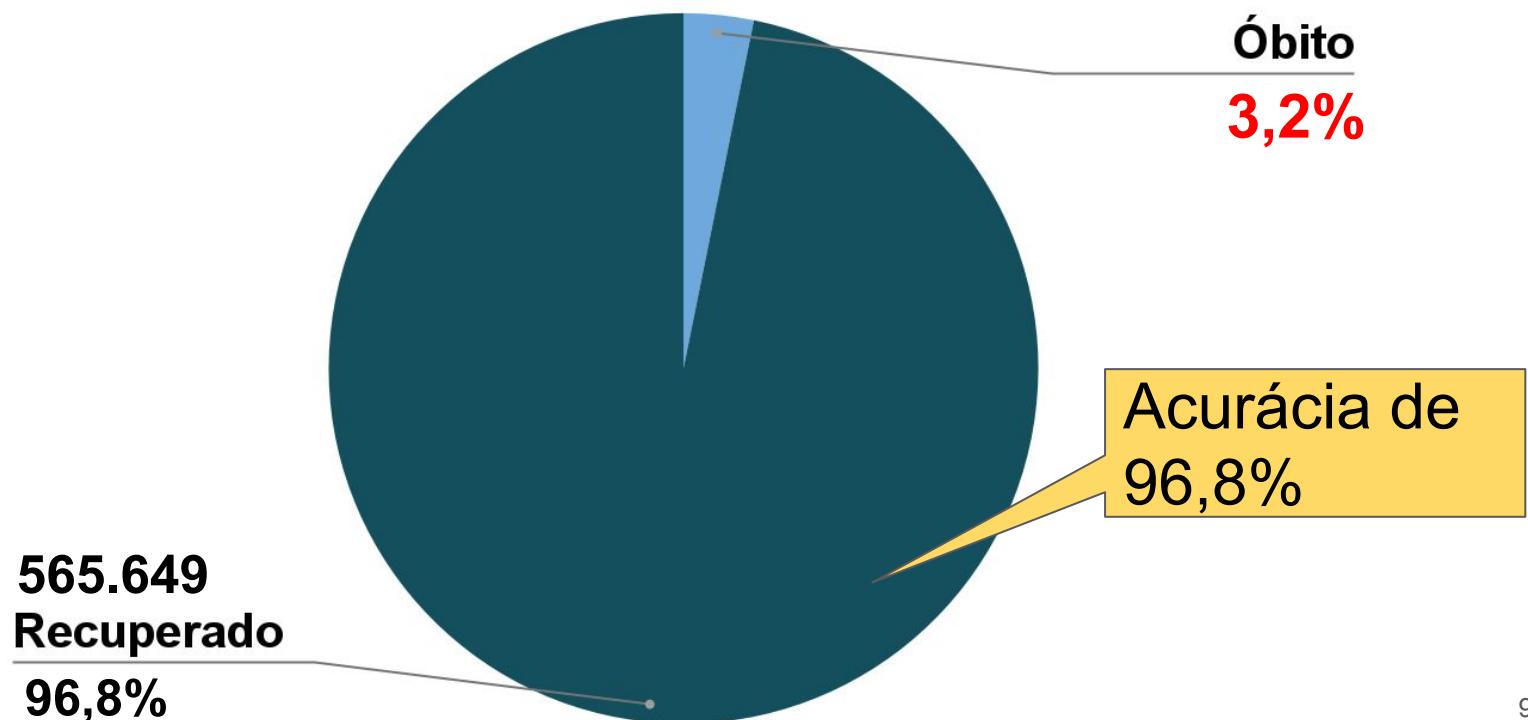


18.579
Óbito
3,2%

565.649
Recuperado
96,8%

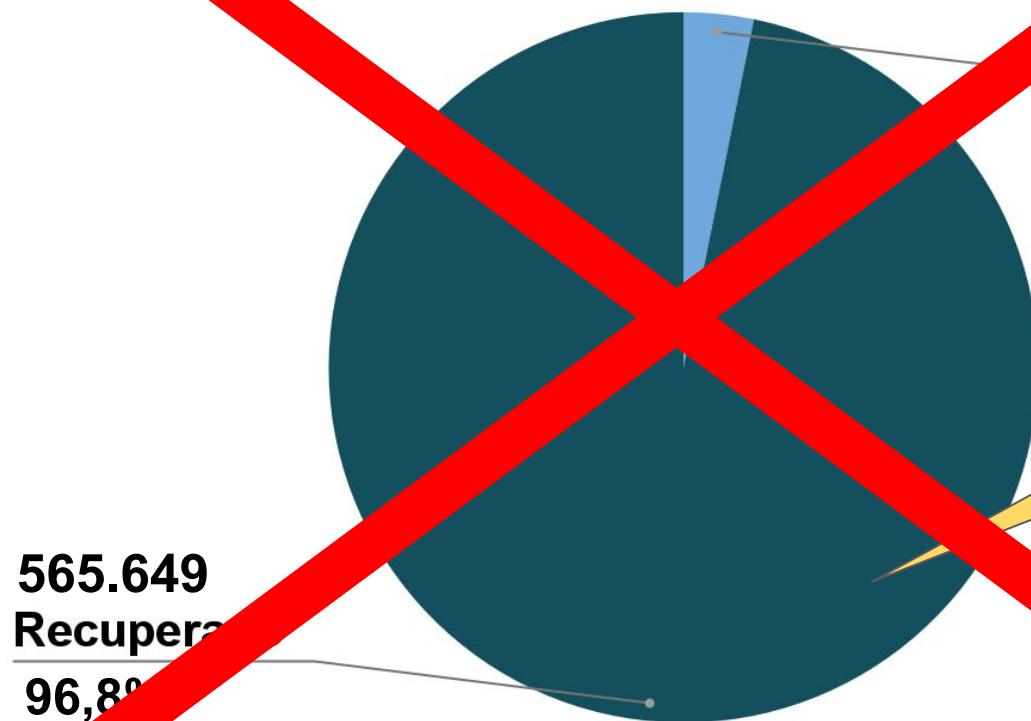
EVOLUÇÃO

Distribuição das evoluções



EVOLUÇÃO

Distribuição das evoluções



18.579
Óbito
3,2%

Acurácia de
96,8%

565.649

Recuperado

96,8%

A relação entre Prognóstico Real e Preditivo

REAL

RECUPERADO	Verdadeiro negativo	Falso Positivo
ÓBITO	Falso Negativo	Verdadeiro Positivo
	RECUPERADO	ÓBITO

PREDITO

A relação entre Prognóstico Real e Preditivo

REAL

RECUPERADO	Verdadeiro negativo	Falso Positivo
ÓBITO	Falso Negativo	Verdadeiro Positivo
	RECUPERADO	ÓBITO
PREDITO		

A relação entre Prognóstico Real e Preditivo

REAL

RECUPERADO	Verdadeiro negativo	Falso Positivo
ÓBITO	Falso Negativo	Verdadeiro Positivo
	RECUPERADO	ÓBITO
PREDITO		

A relação entre Prognóstico Real e Preditivo

REAL

RECUPERADO	Verdadeiro negativo	Falso Positivo
ÓBITO	Falso Negativo	Verdadeiro Positivo
	RECUPERADO	ÓBITO
PREDITO		

A relação entre Prognóstico Real e Preditivo

REAL

RECUPERADO	Verdadeiro negativo	Falso Positivo
ÓBITO	Falso Negativo	Verdadeiro Positivo
	RECUPERADO	ÓBITO
PREDITO		

A relação entre Prognóstico Real e Preditivo

MATRIZ DE CONFUSÃO

REAL

RECUPERADO	Verdadeiro negativo	Falso Positivo
ÓBITO	Falso Negativo	Verdadeiro Positivo
	RECUPERADO	ÓBITO
PREDITO		

Taxa de Verdadeiro Positivo (TPR) / Revocação

REAL

RECUPERADO	Verdadeiro negativo (D)	Falso Positivo (B)
ÓBITO	Falso Negativo (C)	Verdadeiro Positivo (A)
	RECUPERADO	ÓBITO

$$TPR = A / (A + C)$$

PREDITO

Taxa de Falso Positivo (FPR) = *Fall-out*

REAL

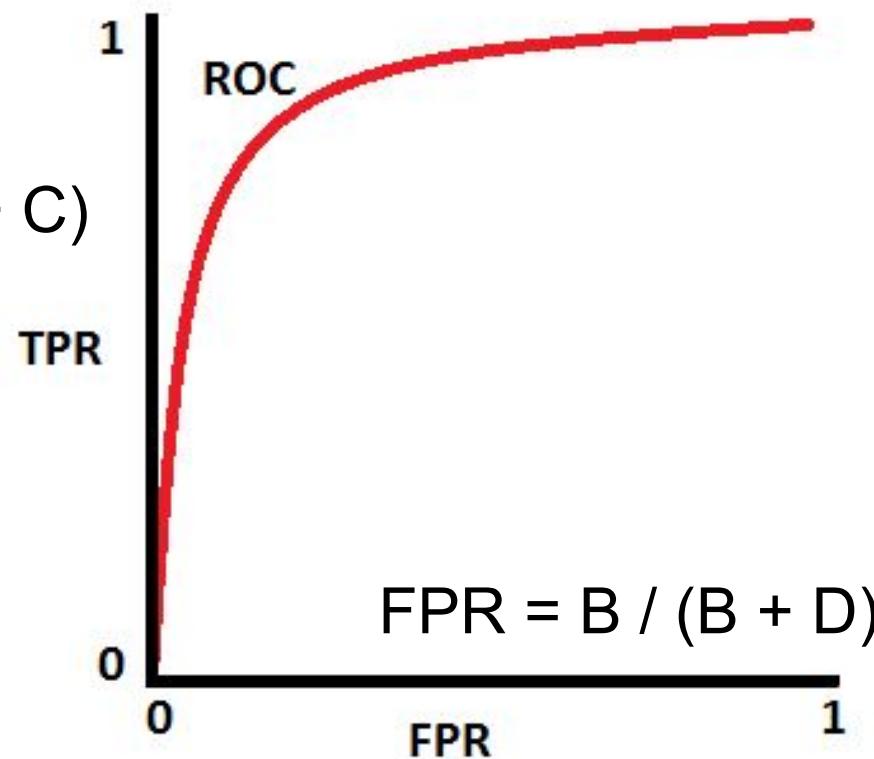
RECUPERADO	Verdadeiro negativo (D)	Falso Positivo (B)
ÓBITO	Falso Negativo (C)	Verdadeiro Positivo (A)
	RECUPERADO	ÓBITO

PREDITO

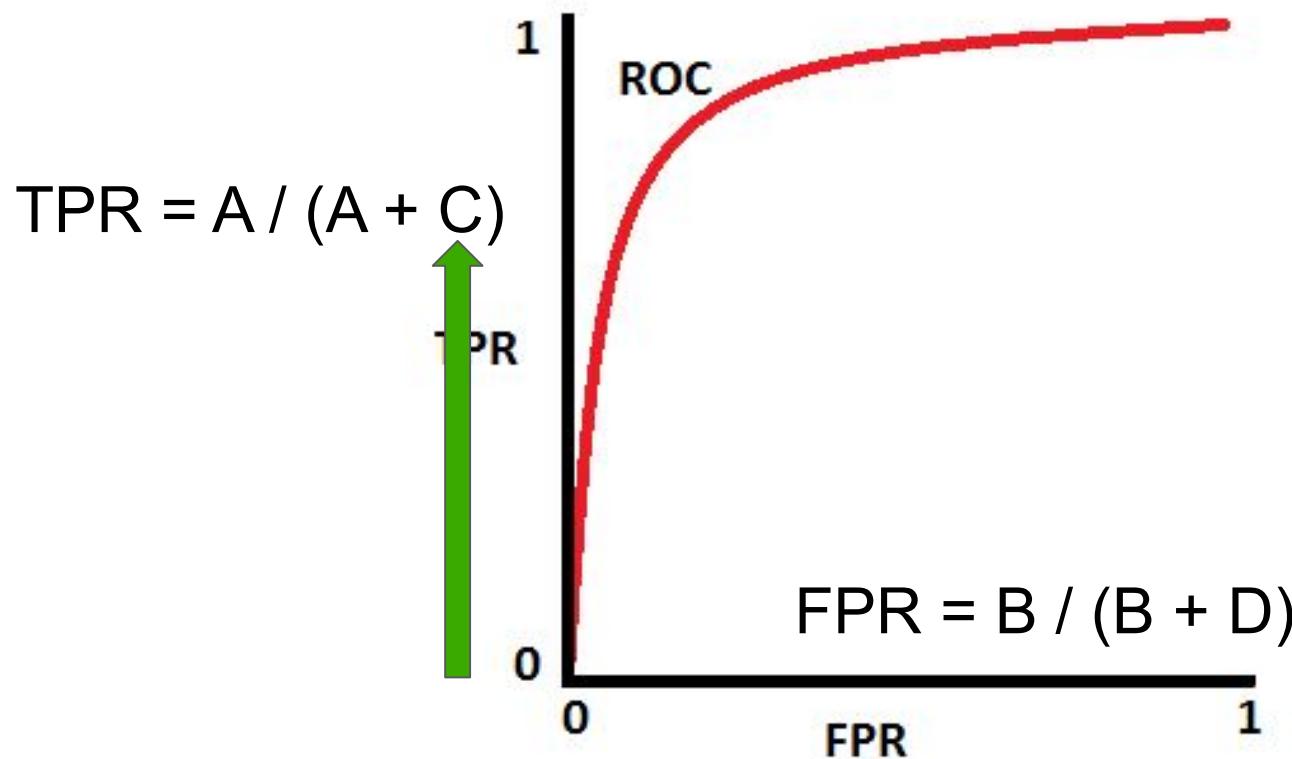
$$FPR = B / (B + D)$$

Métrica de avaliação - Curva ROC

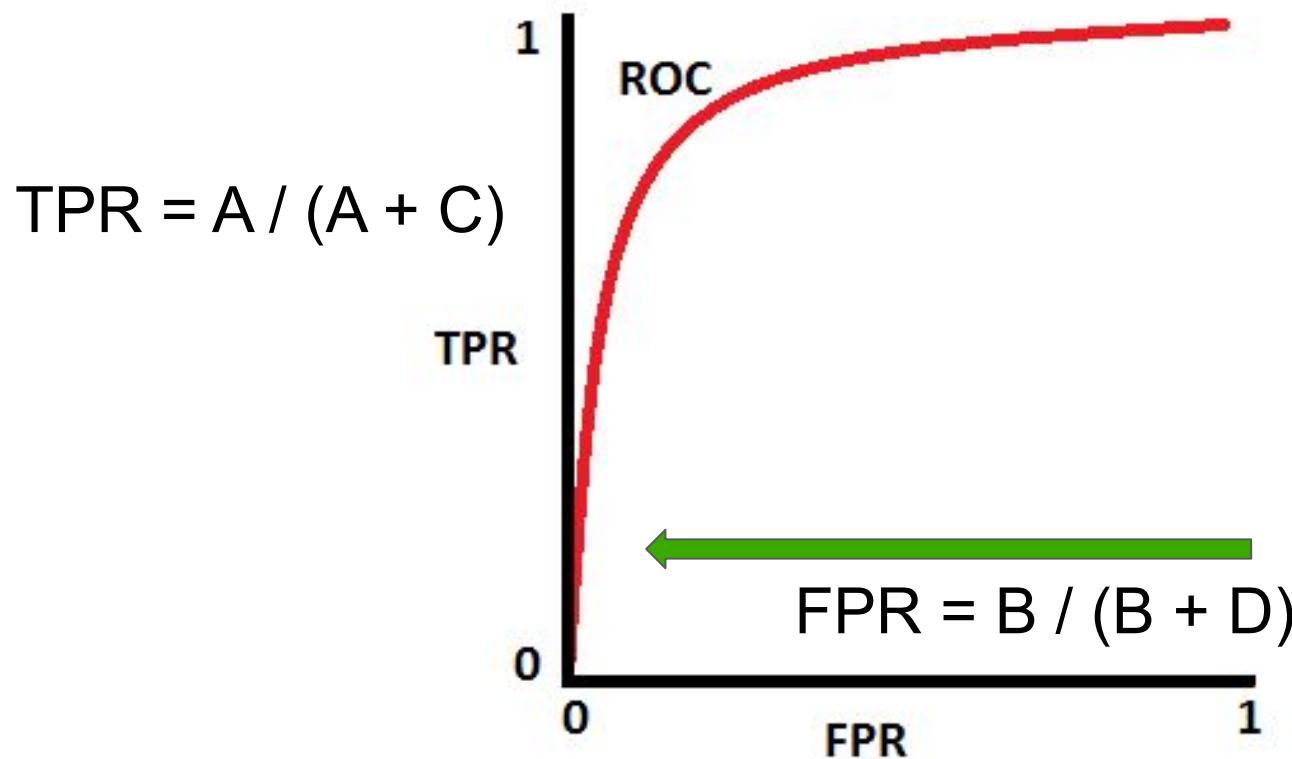
$$TPR = A / (A + C)$$



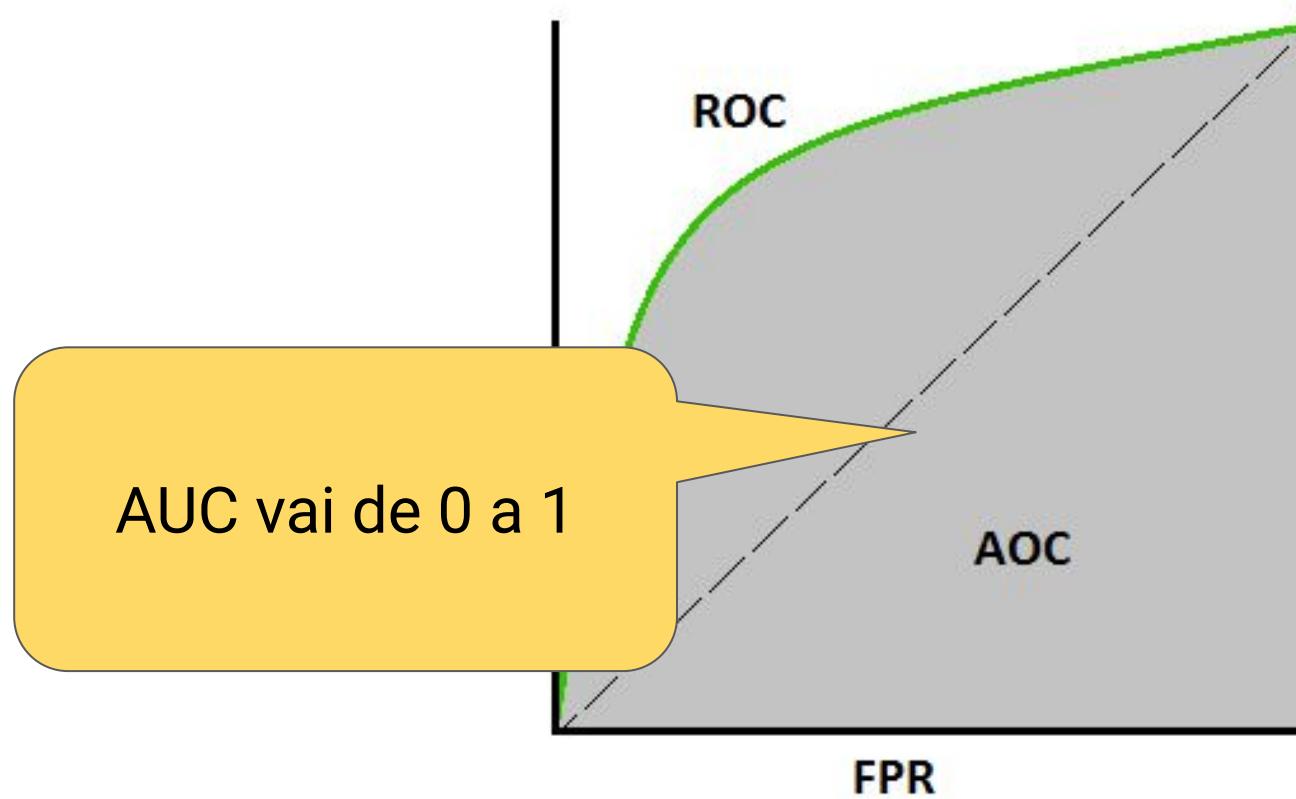
Métrica de avaliação - Curva ROC



Métrica de avaliação - Curva ROC



Métrica de avaliação - Área sob a Curva ROC (AUC-ROC)

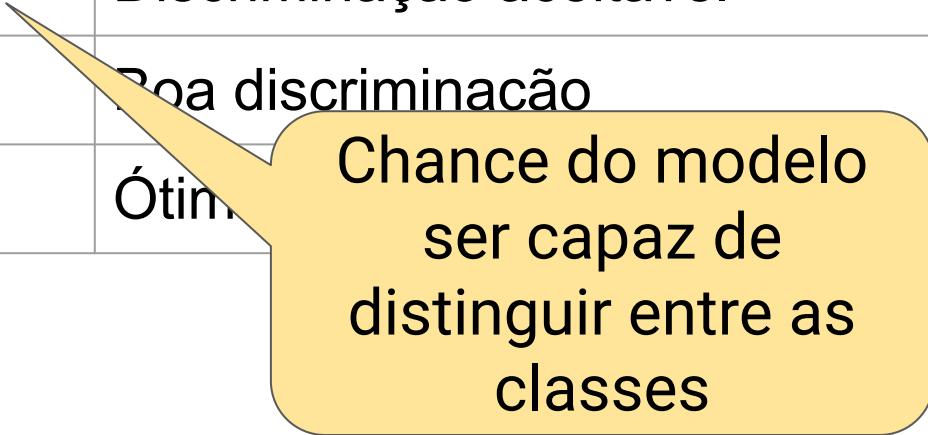


Métrica de avaliação - AUC-ROC

Score AUC	Classificação
0,5	Sem capacidade de discriminação
0,5 ~ 0,7	Discriminação pobre
0,7 ~ 0,8	Discriminação aceitável
0,8 ~ 0,9	Boa discriminação
> 0,9	Ótima discriminação

Métrica de avaliação - AUC-ROC

Score AUC	Classificação
0,5	Sem capacidade de discriminação
0,5 ~ 0,7	Discriminação pobre
0,7 ~ 0,8	Discriminação aceitável
0,8 ~ 0,9	Boa discriminacão
> 0,9	Ótima



Chance do modelo
ser capaz de
distinguir entre as
classes

Roteiro

Estado da arte

Design do estudo e origem dos dados

Variáveis (características)

Métodos estatísticos

Implementação e resultados

Conclusão e considerações finais

Tecnologías utilizadas



Análise descritiva

Correlação

	EVOLUÇÃO
SRAG	0.6
CARDIOPATIA	0.4
DISPNEIA	0.3
DIABETES/DOENÇA RESPIRATÓRIA/OBESIDADE	0.2

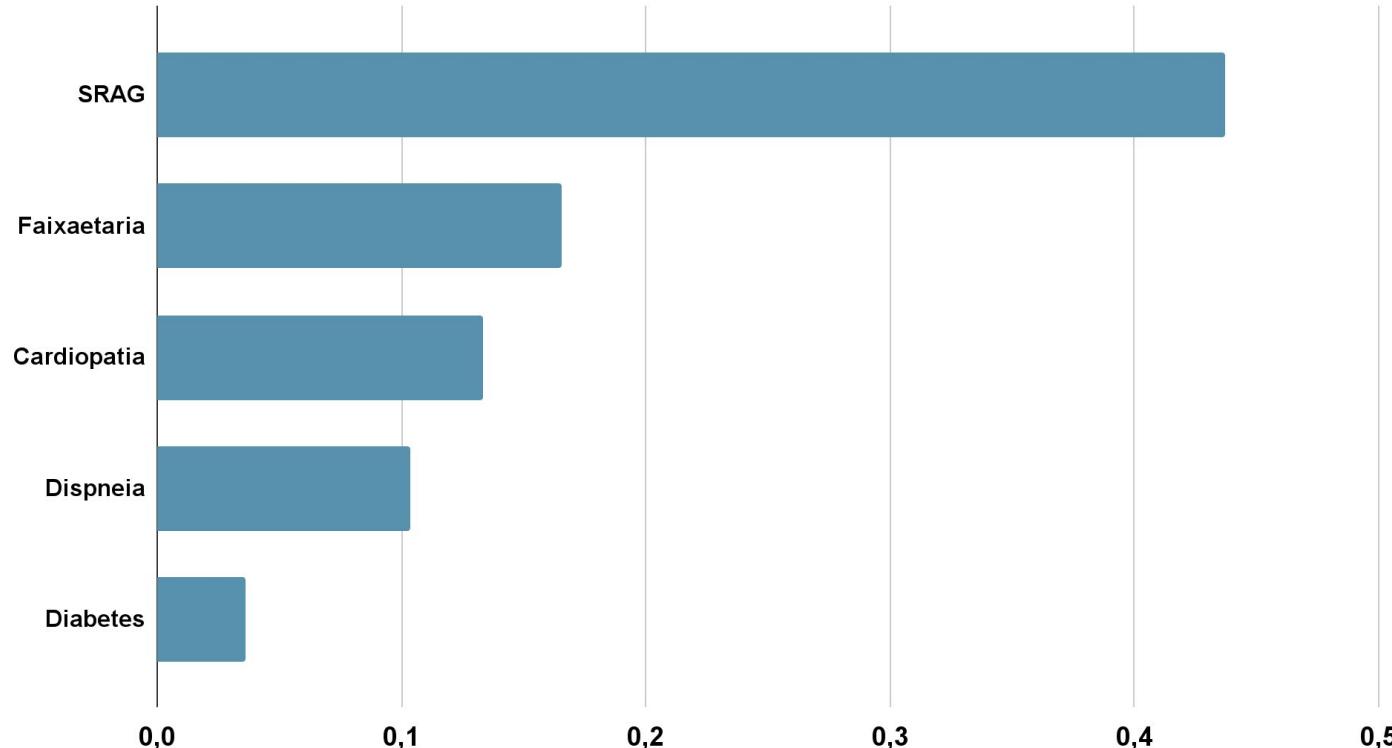
Correlação

Não implica
causalidade

	EVOLUÇÃO
CARDIOPATIA	0.6
DISPNEIA	0.4
DIABETES/DOENÇA RESPIRATÓRIA/OBESIDADE	0.3
	0.2

Importância das características

Importância das características - Floresta aleatória (Gini)



Importância das características

Maiores preditoras

SRAG

Faixa etária

Cardiopatia

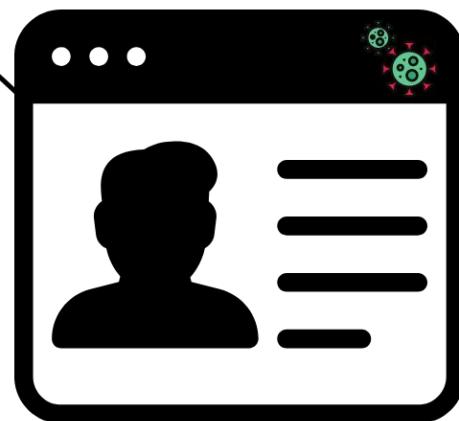
Dispneia

Diabetes

Perfil dos pacientes

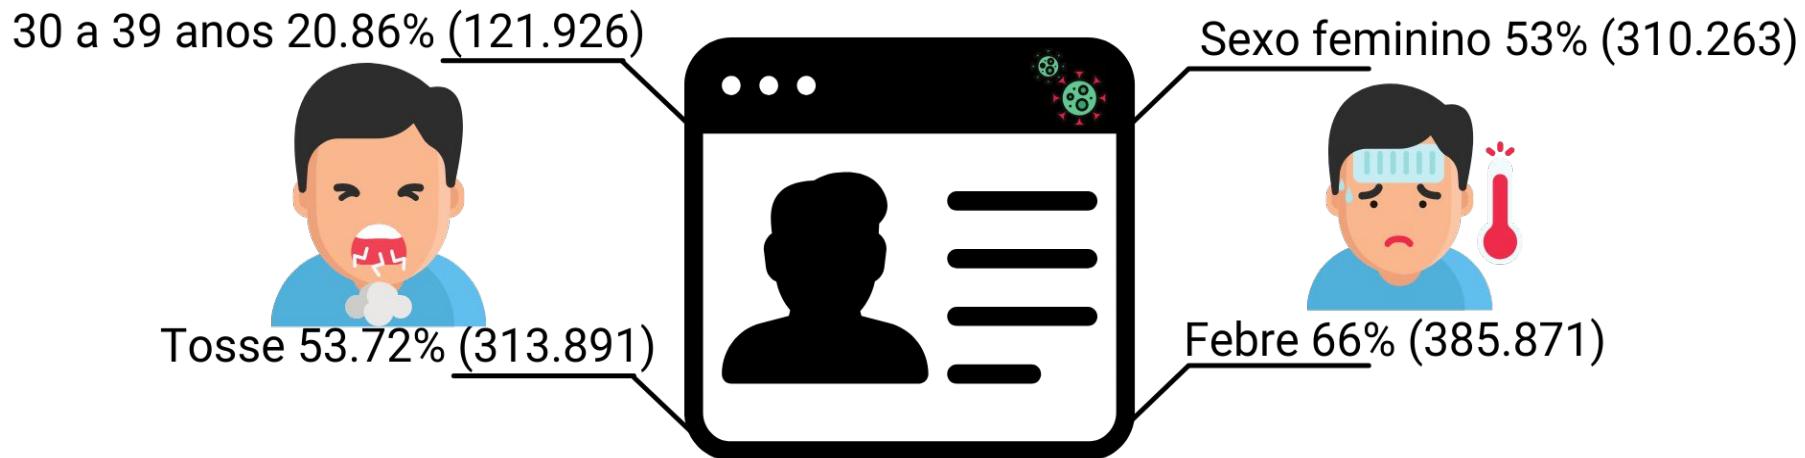
Perfil dos pacientes

30 a 39 anos 20.86% (121.926)



Sexo feminino 53% (310.263)

Perfil dos pacientes



Maiores condições de letalidade

	Total de casos	Total óbitos	Letalidade
Cardiopatia	16.981	7.728	45,50%
Doença respiratória	3.566	1.552	43,52%
Doença cromossômica	141	58	41,13%
Problema renal	2.254	861	38,19%
SRAG	51.691	18.579	35,94%
Obesidade	10.855	2.868	26.42%
Diabetes	22.627	5.593	24.71%

Desempenho do modelo

Performance do modelo - Teste

	PONTUAÇÃO AUC-ROC	
	Média (5-V.C.)	I.C. = 95%
Floresta aleatória (com raça/cor)	0.539	(0.528, 0.550)
Floresta aleatória	0.705	(0.694, 0,716)
Floresta aleatória (subamostragem)	0.969	(0.968, 0.970)
Floresta aleatória (subamostragem + tunagem de hiperparâmetro)	0.981	(0.981, 0.982)

Performance do modelo - Teste

	PONTUAÇÃO AUC-ROC	
	Média (5-V.C.)	I.C. = 95%
Floresta aleatória (com raça/cor)	0.539	(0.528, 0.550)
Floresta aleatória	0.705	(0.694, 0,716)
Floresta aleatória (subamostragem)	0.969	(0.968, 0.970)
Floresta aleatória (subamostragem + tunagem de hiperparâmetro)	0.981	(0.981, 0.982)

Performance do modelo - Teste

PONTUAÇÃO AUC-ROC		
	Média (5-V.C.)	I.C. = 95%
Floresta aleatória (com raça/cor)	0.539	(0.528, 0.550)
Floresta aleatória	0.705	(0.694, 0,716)
Floresta aleatória (subamostragem)	0.969	(0.968, 0.970)
Floresta aleatória (subamostragem + tunagem de hiperparâmetro)	0.981	(0.981, 0.982)

Performance do modelo - Teste

	PONTUAÇÃO AUC-ROC	
	Média (5-V.C.)	I.C. = 95%
Linha de base	0.539	(0.528, 0.550)
Floresta aleatória	0.705	(0.694, 0,716)
Floresta aleatória (subamostragem)	0.969	(0.968, 0.970)
Floresta aleatória (subamostragem + tunagem de hiperparâmetro)	0.981	(0.981, 0.982)

Melhorias

Performance do modelo - Teste

	PONTUAÇÃO AUC-ROC	
	Média (5-V.C.)	I.C. = 95%
Floresta aleatória (com raça/cor)	0.539	(0.528, 0.550)
Floresta aleatória	0.705	(0.694, 0,716)
Floresta aleatória (subamostragem)	0.969	(0.968, 0.970)
Floresta aleatória (subamostragem + tunagem de hiperparâmetro)	0.981	(0.981, 0.982)

Performance do modelo - Teste

	PONTUAÇÃO AUC-ROC	
	Média (5-V.C.)	I.C. = 95%
Random Forest subamostragem	0.539	(0.528, 0.550)
Floresta aleatória	0.705	(0.694, 0.716)
Floresta aleatória (subamostragem)	0.969	(0.968, 0.970)
Floresta aleatória (subamostragem + tunagem de hiperparâmetro)	0.981	(0.981, 0.982)

Melhoria de
37.44%

Performance do modelo - Teste

	PONTUAÇÃO AUC-ROC	
	Média (5-V.C.)	I.C. = 95%
Floresta aleatória (com resample)	0.539	(0.528, 0.550)
Floresta aleatória (subamostragem)	0.705	(0.694, 0.716)
Floresta aleatória (subamostragem)	0.969	(0.968, 0.970)
Floresta aleatória (subamostragem + tunagem de hiperparâmetro)	0.981	(0.981, 0.982)

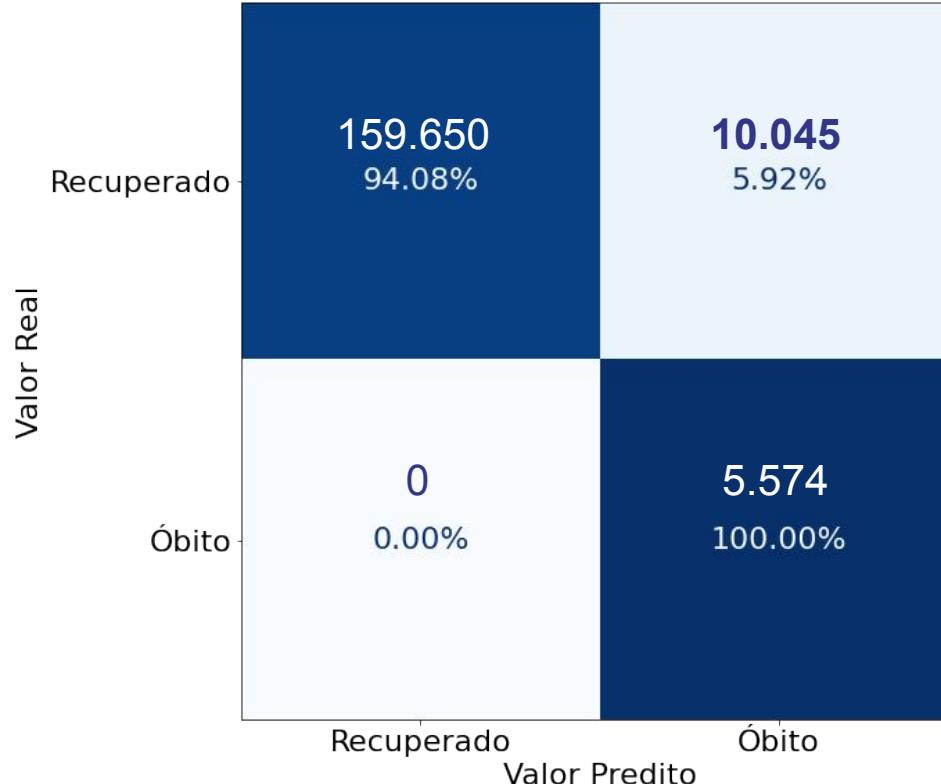
Melhoria de
1.23%

Performance do modelo - Validação



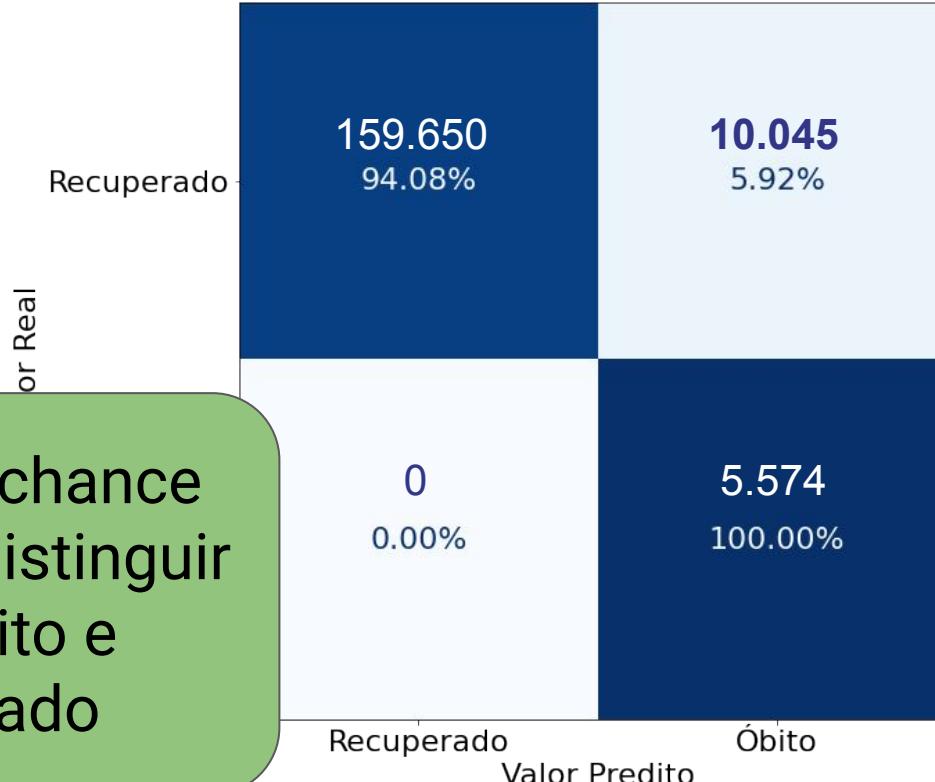
Performance do modelo - Validação

AUC-ROC:
0.970



Performance do modelo - Validação

AUC-ROC:
0.970



Há **97%** de chance
do modelo distinguir
entre óbito e
recuperado

Roteiro

Estado da arte

Design do estudo e origem dos dados

Variáveis (características)

Métodos estatísticos

Implementação e resultados

Conclusão e considerações finais

Limitações

Limitações

Alguns preditores não estão disponíveis

Limitações

Alguns preditores não estão disponíveis
Como re-treinar o modelo?

Limitações

Alguns preditores não estão disponíveis

Como re-treinar o modelo?

Registros de reinfecção?

Limitações

Alguns preditores não estão disponíveis

Como re-treinar o modelo?

Registros de reinfecção?

Apenas um algoritmo de *machine learning*

Conclusões

Modelo com alta discriminação

Modelo com alta discriminação

0.97
AUC-ROC

Modelo com alta discriminação

Diminuição da subjetividade na tomada de decisão

Modelo com alta discriminação

Diminuição da subjetividade na tomada de decisão

É uma ferramenta auxiliar

Considerações finais

12 meses de desenvolvimento do trabalho

12 meses de desenvolvimento do trabalho

+ 10 cursos

+ 1000 horas de estudo

**12 meses de desenvolvimento do trabalho
Aprendizados, testes e linhas de código escritas**

**12 meses de desenvolvimento do trabalho
Aprendizados, testes e linhas de código escritas
Um trabalho em conjunto com a prefeitura de
Santa Maria**

Estudos

BOLETIM EPIDEMIOLÓGICO | COVID-19

29 de jun. de 2021

Confirmados
39.982

Descartados
6.787

Suspeitos
1.273

Curados
36.783

Casos ativos*
176

Óbitos
752

(*): Casos ativos: número de pessoas que ainda é capaz de transmitir a Covid-19

Situação

Santa Maria

Descartado	6.787
Suspeito	1.273
Total Geral	109.294
Síndrome Gripal Não Especificada	61.252
Confirmado Laboratorial	36.024

Região

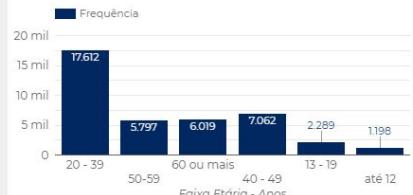
Casos Confirmados

Óbitos

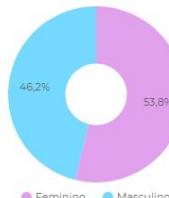
RS	1.214.290	31.280
Santa Maria	39.982	752
Brasil	18.513.305	515.985
Mundo	181.598.664	3.932.872

(*): Confirmados clínico-epidemiológico, clínico-imagem e clínico

Faixa Etária



Porcentagem de casos por Sexo



Controle de Testes*

Data de Atualização

Total

18 de jun. de 2021

77.792

(*): As atualizações serão semanais

Testes Rápidos

Realizados *

6.720

Testes PCR*

Lacen

259

12 meses de desenvolvimento do trabalho
Aprendizados, testes e linhas de código escritas
Um trabalho em conjunto com a prefeitura de
Santa Maria
Do quase zero ao primeiro emprego na área de
dados (combateafraude.com)

Análise de dados

Aprendizado de máquina

Estatística descritiva

+ programação em Python

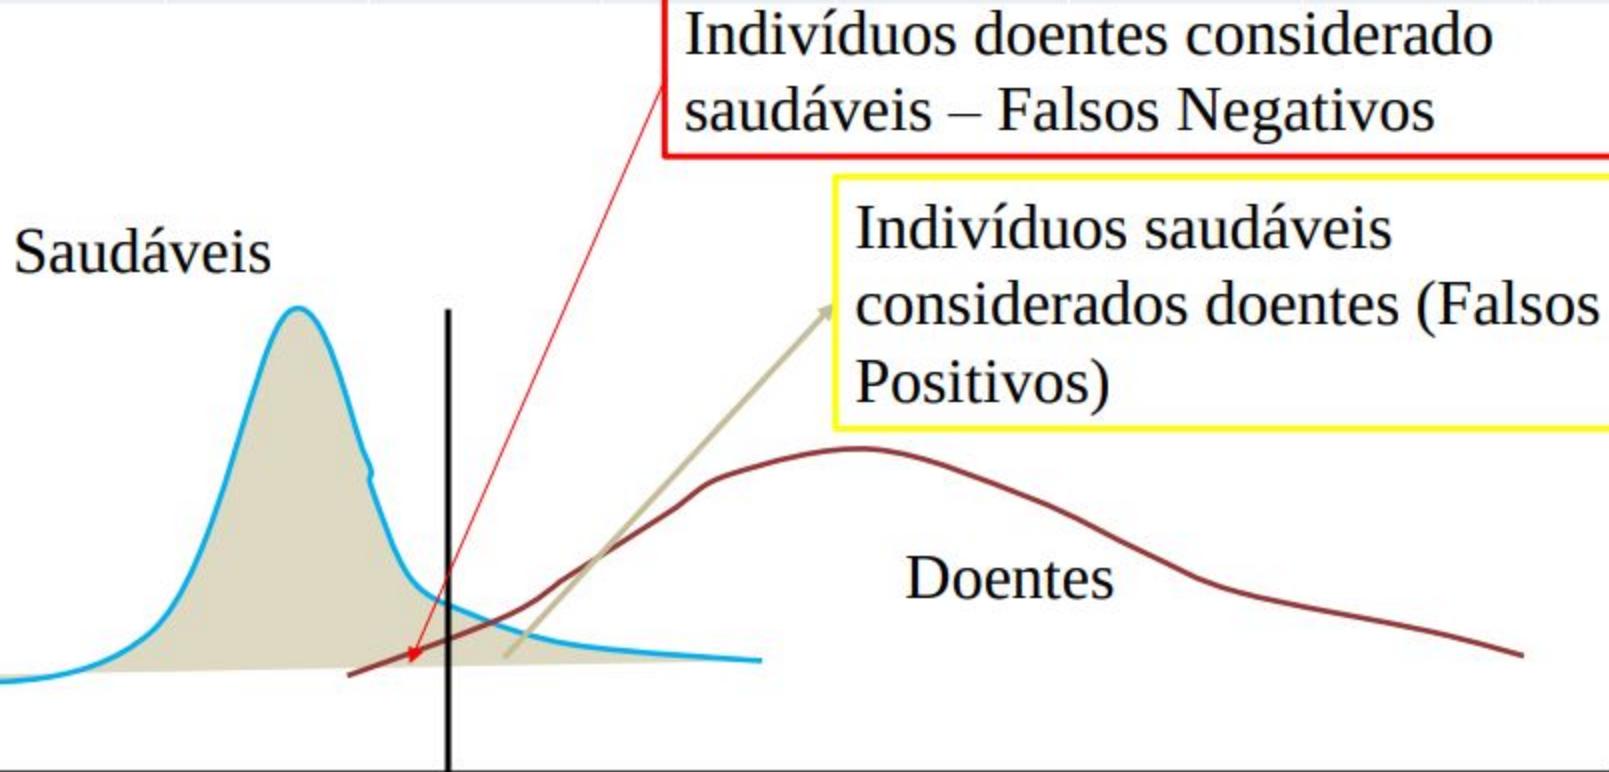
Escrita sucinta

Passar o conhecimento

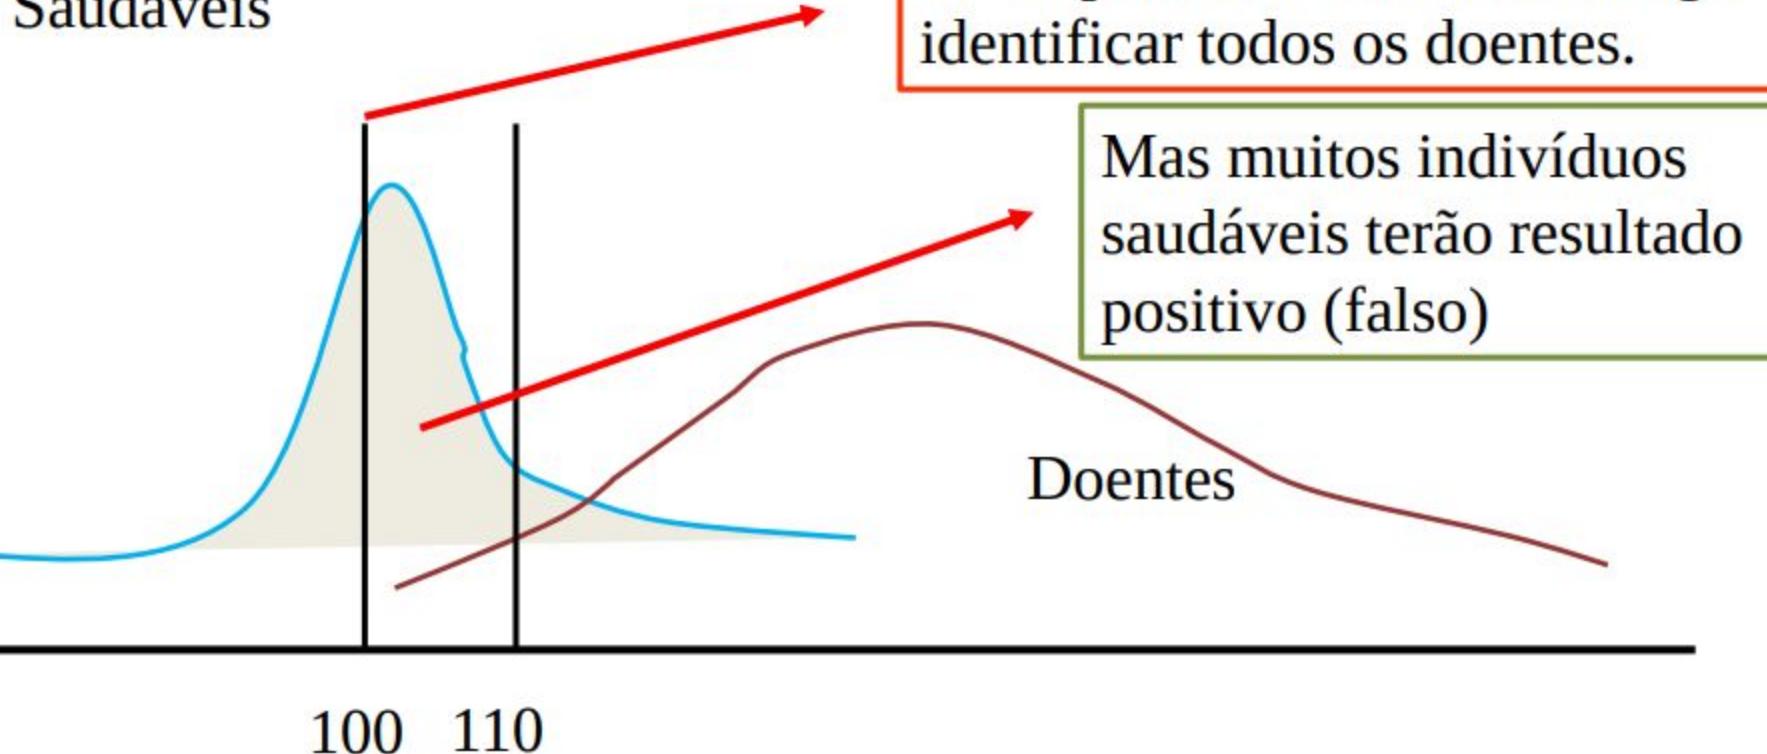


Obrigado!

gustavorodrigues.aluno@unipampa.edu.br



Saudáveis

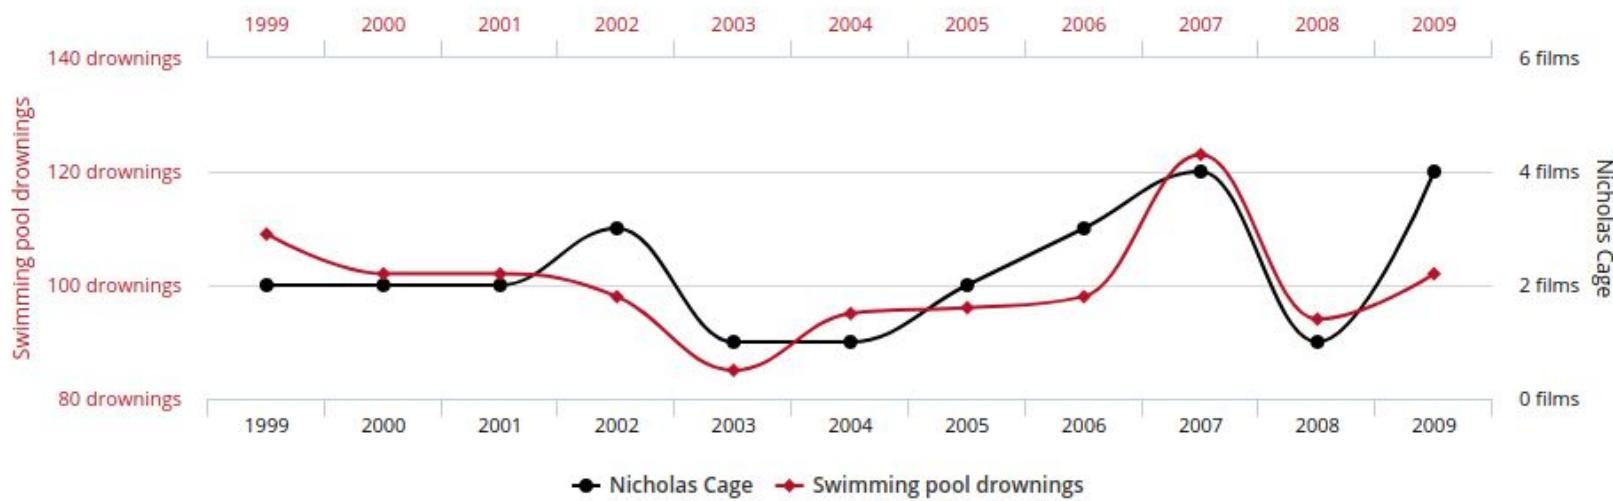


Correlação

Number of people who drowned by falling into a pool correlates with Films Nicolas Cage appeared in



Correlation: 66.6% ($r=0.666004$)



tylervigen.com

Data sources: Centers for Disease Control & Prevention and Internet Movie Database

Objetivo

Propor um **modelo preditivo** para **classificação de risco de mortalidade** de pacientes com COVID-19 no estado do Rio Grande do Sul

